

Modelización masiva de series temporales

TRABAJO FIN DE GRADO

Curso 2024 /2025



UNIVERSIDAD COMPLUTENSE
DE MADRID

FACULTAD DE CIENCIAS MATEMÁTICAS

GRADO EN Matemáticas y Estadística

Estudiante:

David Izquierdo Valentín

Director/es:

Daniel Vélez Serrano

Madrid, 25 de junio de 2025

Autorización de difusión

David Izquierdo Valentín

25 de junio de 2025

El abajo firmante, matriculado en el Grado en Matemáticas y Estadística de la Facultad de Ciencias Matemáticas, autoriza a la Universidad Complutense de Madrid (UCM) a difundir y utilizar con fines académicos, no comerciales y mencionando expresamente a su autor el presente Trabajo Fin de Grado: “Estimación masiva de series temporales”, realizado durante el curso académico 2024-2025 bajo la dirección de Daniel Vélez Serrano en el Departamento de Estadística e Investigación Operativa, y a la Biblioteca de la UCM a depositarlo en el Archivo Institucional E-Prints Complutense con el objeto de incrementar la difusión, uso e impacto del trabajo en Internet y garantizar su preservación y acceso a largo plazo.

Resumen en castellano

En el presente Trabajo de Fin de Grado se estudia y analiza el impacto de diferentes estrategias de predicción masiva de series temporales. Desde un marco teórico básico, se amplían los conceptos de series multivariantes, variables exógenas y estructuras jerárquicas con el fin de realizar una evaluación real de las técnicas de estimación masiva.

Sobre un caso real, la compraventa de viviendas en España entre los años 2009/2019, se aplicará la metodología de *Box-Jenkins* y se comprobará el efecto de las estrategias *Bottom-up*, *Top-down* y *Middle-out* sobre un sistema jerárquico. Para ello se ha llevado a cabo la creación de una función de búsqueda que consigue reproducir el ajuste de series de forma automática, teniendo en cuenta todos los aspectos teóricos. Paralelamente, se comprobará qué métrica de error proporciona mejores resultados.

Palabras clave

Series temporales, estimaciones masivas, metodología Box-Jenkins, sistemas jerárquicos, *Bottom-up*, *Top-down*, *Middle-out*.

Abstract

In this Bachelor's Thesis, the impact of different large-scale time series forecasting strategies is studied and analyzed. Starting from a basic theoretical framework, the concepts of multivariate time series, exogenous variables, and hierarchical structures are expanded upon to conduct a realistic evaluation of large-scale estimation techniques.

Using a real-world case study—housing transactions in Spain between 2009 and 2019—the *Box-Jenkins* methodology will be applied, and the effect of *Bottom-up*, *Top-down*, and *Middle-out* strategies on a hierarchical system will be examined. To achieve this, a search function has been developed to automate the time series fitting process, incorporating all relevant theoretical considerations. Additionally, the study will assess which error metric yields the most accurate results.

Keywords

Time series, large-scale forecasting, Box-Jenkins methodology, hierarchical systems, *Bottom-up*, *Top-down*, *Middle-out*

Índice general

Índice	I
Agradecimientos	III
1. Introducción	1
1.1. Objetivos y antecedentes	1
2. Metodología	3
2.1. Conceptos preliminares	3
2.1.1. Definición de serie temporal	3
2.1.2. Definición de estacionariedad	4
2.1.3. Procesos ARIMA	6
2.1.4. Procesos SARIMA	8
2.1.5. Modelos multivariantes	11
2.1.6. Tratamiento de intervenciones y <i>outliers</i>	12
2.2. Metodología <i>Box-Jenkins</i>	13
2.2.1. Identificación	14
2.2.2. Estimación	14
2.2.3. Validación	14
2.2.4. Predicción	15
2.3. Estimaciones masivas	16
2.3.1. Modelos jerárquicos	16
2.3.2. Estimación <i>Bottom-up</i>	18
2.3.3. Estimación <i>Top-down</i>	18
2.3.4. Estimación <i>Middle-out</i>	19
2.4. Función de búsqueda	19
3. Aplicación práctica	21
3.1. Descripción del procedimiento	22

3.2.	Conjunto de datos	22
3.3.	Análisis de la serie	22
3.3.1.	Consideraciones previas	23
3.3.2.	Ajuste manual de la serie	24
3.4.	Análisis datos autonómicos y provinciales	32
3.5.	Estrategia <i>Bottom-up</i>	35
3.6.	Estrategia <i>Top-down</i>	36
3.7.	Estrategia <i>Middle-out</i>	38
3.8.	Discusión	38
4.	Conclusiones	40
	Bibliography	41
A.	Anexo	42
A.1.	Momentos de los procesos básicos	42
A.1.1.	Proceso de medias móviles	42
A.1.2.	Proceso autorregresivo	43
A.2.	Esquema jerárquico de la base de datos	43
A.3.	Ajuste manual	44
A.3.1.	Matriz de correlaciones modelo SARIMA(1,0,0)×(1,0,0)[12] con varia- bles explicativas sin bisiesto	44
A.3.2.	Líneas aéreas	44
A.4.	Cálculo de predicciones	45
A.5.	Tabla modelos autonómicos y provinciales	47
A.5.1.	Tabla modelo por comunidad	47
A.5.2.	Tabla modelo por provincia	48
A.6.	Predicciones Bottom-up	50
A.6.1.	Modelos por comunidades	50
A.6.2.	Modelos por provincias	52
A.7.	Error MAPE modelos provinciales	54
A.8.	Tabla errores <i>MAPE</i> de predicciones provinciales	55
B.	Código	56

Agradecimientos

A mis familiares y amigos por acompañarme en este periodo haciendo de él más agradable y ameno.

La guía de Daniel Vélez Serrano por orientar en este proceso y mi aprendizaje hacia mis preferencias profesionales aportando un gran valor. Al profesor Antonio Alberto Rodríguez Sousa, por despertar un claro interés por esta disciplina.

Oportunidades y nuevos retos surgen gracias a este proyecto donde he podido descubrir un gran interés por mi futuro profesional ligado a esta disciplina.

Capítulo 1

Introducción

Desde el inicio del análisis de datos, una de las principales disciplinas ha sido el estudio de la evolución del objeto de estudio con respecto al tiempo. Las series temporales permiten estudiar detalladamente este comportamiento y situar el objetivo en predicciones precisas. En el marco del estudio de series temporales existen numerosas ramas y metodologías, que siguiendo patrones de ejecución diferentes, buscan las mejores predicciones. En el contexto global actual, donde priman las extensas bases de datos, el análisis de series temporales ha avanzado en paralelo con las estimaciones masivas. Las aplicaciones de la teoría básica se han adaptado para ofrecer una mejora en prestaciones en este contexto. Han surgido técnicas para cada situación, que perfeccionan la precisión de los resultados. Centraremos pues este documento, en el ámbito de la estimación masiva de series temporales con el fin de actualizar los contenidos recientes de esta disciplina.

1.1. Objetivos y antecedentes

El rápido desarrollo de la tecnología y la información en estos últimos años ha iniciado una época de cambios donde el aprendizaje automático y el *Big Data* han comenzado a tomar el lugar del análisis de series temporales. Redes neuronales y otros algoritmos han surgido para aportar nuevos acercamientos a soluciones más precisas y más eficientes. Sin embargo, el análisis de series temporales también ha evolucionado con la aparición de técnicas innovadoras en la materia.

Las primeras apariciones sobre la cuestión de estimar grandes cantidades de series surgieron durante la década de los ochenta. Las primeras referencias datan de 1982 en las

conocidas como "Las competencias M"⁸, competencias organizadas por el profesor *Spyros Makridakis* y su equipo, donde se retaba a una serie de concursantes a conseguir las mejores predicciones. Este concurso se amplió a más de 1000 series con diferentes instantes temporales y de diferentes contextos para garantizar la precisión y calidad de los resultados obtenidos. En este primer evento los modelos empleados distan de lo que hoy en día conocemos como estimación masiva, pero se cree que sentaron las bases para un desarrollo más profundo. Estas competencias siguen en desarrollo con novedosos problemas a resolver donde ya si que incluyen estrategias de predicción masiva.

Los sistemas jerárquicos y las metodologías de estimación masiva se estudiaron en profundidad por los profesores *Rob J. Hyndman* y *George Athanasopoulos*⁶. Su estudio supuso una referencia para el futuro de la estimación masiva. Se estudiaron diferentes relaciones lógicas entre los datos y cómo afrontar de manera más efectiva su predicción. Surgieron así las tres técnicas de estimación que comentaremos más adelante, *Bottom-up*, *Top-down* y *Middle-out*.

La referencia más reciente para este documento ha sido la competición de *Mkridakis M5*, *M5 Accuracy Competition: Results, Findings, and Conclusions*⁹, una de las recientes competencias *M* que, en 2021, enfrentaron el problema de precisión sobre unos datos jerárquicos de la empresa *Walmart* con más de 40.000 series. Desde la primera competición se han ido ajustando las reglas y parámetros para aumentar la precisión de los resultados. Las cuestiones sobre la métrica de referencia siguen abiertas, pero con una tendencia hacia errores medios porcentuales (*MAPE*) u otras como la raíz del error cuadrático medio, *RMSSE*.

A pesar de la rápida evolución de los modelos avanzados de aprendizaje automático, la disciplina de series temporales presenta fortalezas suficientes para continuar aportando innovaciones al estudio de predicciones. En este contexto, nos plantearemos una posible mejora respecto a los algoritmos de estimaciones masivas, incluyendo la validación de las hipótesis y significatividad del modelo frente a los algoritmos ya existentes.

Capítulo 2

Metodología

En este capítulo se presentan, en primer lugar, algunos conceptos básicos de series temporales como los populares modelos *ARIMA* y la Metodología *Box-Jenkins*. Posteriormente, se exponen diferentes estrategias de estimación masiva de series temporales.

2.1. Conceptos preliminares

2.1.1. Definición de serie temporal

Una **serie temporal** se corresponde con cualquier conjunto de datos tomados en instantes de tiempos ordenados y equidistantes. George E. P. Box y Gwilym M. Jenkins³ definen una serie temporal de la siguiente manera:

Definición 1. *Una serie temporal $z_1, z_2, \dots, z_N$ de N observaciones sucesivas se considera como una muestra de una población infinita de series temporales que podrían haber sido generadas por el mismo proceso estocástico.*

Definición 2. *Un proceso estocástico se define para un espacio muestral Ω , un conjunto de instantes de tiempo ($T \equiv \mathbb{Z}$) y un el conjunto de estados S , como:*

$$X : \Omega \times T \rightarrow S. \tag{2.1}$$

Definición 3. *Una serie temporal es una realización de un proceso estocástico, esto es, el resultado de, fijar w y dejar variar t .*

Asociado a cada una de estas variables aleatorias temporales $X_w(t)$ (en adelante X_t o $X(t)$) podremos definir sus momentos:

1. Media:

$$\mu_t = E[X(t)] \quad (2.2)$$

2. Varianza:

$$\sigma_t^2 = E[(X(t) - \mu_t)^2] \quad (2.3)$$

3. Covarianza entre los instantes t_1 y t_2 :

$$C_X(t_1, t_2) = E[(X(t_1) - \mu_{t_1})(X(t_2) - \mu_{t_2})] \quad (2.4)$$

4. Correlación entre los instantes t_1 y t_2 :

$$\rho_X(t_1, t_2) = \frac{C_X(t_1, t_2)}{\sigma_{t_1} \sigma_{t_2}} \quad (2.5)$$

Sin embargo, de cada instante temporal solo se dispone de un valor de la variable aleatoria correspondiente, por lo que la estimación de tales momentos resulta imposible. Es por esto por lo que se requiere de que el proceso X_t sea estable en el tiempo. Trabajaremos con un proceso llamado estacionario, de modo que el cálculo de los momentos anteriores no está condicionado por el instante de medición.

2.1.2. Definición de estacionariedad

Definición 4. Sea $\{X(t) : t \in T\}$ un proceso, se dice que es **débilmente estacionario** (WSS o Wide Sense Stationary) o simplemente estacionario si cumple:

- $E[X_t] = \mu$ (estacionario en media)
- $\text{Var}(X_t) = \sigma^2$ (estacionario en varianza)
- $\text{Cov}(X_t, X_{t-h}) = \gamma_h \quad \forall t \quad y \quad \forall h$ (estacionario en covarianza)

La interpretación de una serie WSS es aquella en la que la media no varía con el tiempo, es decir, la serie a estudiar no presenta tendencia, ni positiva ni negativa, su varianza no depende del instante t de estudio y la relación entre variables a distancia h solo depende de h y no del instante de medición.

Cuando una serie temporal no es estacionaria, existen diferentes tratamientos para conseguirlo. En primer lugar, trataremos la estacionariedad en varianza, esto es, aquella serie cuya varianza depende del instante t de análisis. Esta alteración de la varianza con el paso del tiempo se puede corregir con el uso de una transformación. Esto es, aplicando una determinada función, eliminamos el efecto de la varianza cambiante en el tiempo.

Uno de los métodos consiste en identificar la mejor transformación de *Box-Cox*, $F(X_t) = w_t = \begin{cases} \log(x_t), & \text{si } \lambda = 0; \\ \frac{x_t^\lambda - 1}{\lambda}, & \text{en otro caso.} \end{cases}$ que es la función a optimizar (Box-Cox, 1964²).

En la práctica, para facilitar la interpretabilidad de los resultados, la mayoría de las series son transformadas mediante logaritmo o raíz cuadrada según los datos.

Definición 5. *El operador de retardos, B , es un operador lineal que retarda en el tiempo el valor de una variable. Sean f, g funciones lineales y a, b parámetros:*

$$B^k(af(t) + bg(t)) = af(t - k) + bg(t - k) \quad (2.6)$$

Definición 6. *El operador diferenciación para un proceso $X(t)$ se define de la siguiente forma:*

$$\nabla_s^m X(t) = (1 - B^s)^m X(t) \quad (2.7)$$

donde el valor m es el número de diferencias aplicadas, mientras que, s es el periodo estacional (si $s = 1$ consideramos la diferenciación regular).

Respecto a la estacionariedad en media, haremos uso del operador diferencia para conseguirlo. La aplicación de una diferencia regular ($m = 1$) a una serie con tendencia lineal o de dos diferencias regulares ($m = 2$) a una serie con tendencia cuadrática, permite eliminar dichas tendencias y lograr estacionariedad en media. Finalmente podremos hacer uso de la diferencia estacional para conseguir estacionariedad en covarianza.

Cabe destacar que, el orden de las diferencias (regular y estacional) no afecta al resultado de la estacionariedad de la serie. No obstante, en casos donde existe un patrón estacional claro, se recomienda comenzar con la diferenciación de este tipo (apartado 8.1 *Rob J Hyndman and George Athanasopoulos*⁶).

El fin último del ajuste de los modelos *ARIMA*, que veremos en el siguiente apartado, es conseguir que el proceso residual tras el ajuste, sea ruido blanco, es decir, algo impredecible desde el punto de vista lineal. Para ello, haremos uso de la definición *White noise process*

propuesta por *Box, George E. P.*, página 28 en su obra *Time Series Analysis: Forecasting and Control*³.

Definición 7. Diremos que X_t es un **proceso de ruido blanco** si:

$$X_t = \varepsilon_t$$

donde ε_t son variables aleatorias independientes e idénticamente distribuidas (en adelante, v.a.i.i.d.) con $\mathbb{E}[\varepsilon_t] = 0$ y $\text{Var}(\varepsilon_t) = \sigma^2$.

2.1.3. Procesos ARIMA

El interés del estudio de series temporales radica en detectar comportamientos e influencias de otros instantes temporales. Para abordar estos aspectos, emplearemos modelos cuya estructura general se basa en dos tipos de dependencias: la influencia del error y la del valor de la serie en instantes anteriores. Trabajaremos con modelos que se ajustan al proceso estocástico subyacente bajo los datos.

En primer lugar, estudiaremos los efectos del error en momentos previos al instante temporal analizado.

Definición 8. Sea ε_t un proceso de ruido blanco. Se dice que X_t es un proceso de medias móviles de orden q , denotado como $MA(q)$, si se escribe:

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2} - \cdots - \theta_q \varepsilon_{t-q} \quad (2.8)$$

siendo $\theta_i, \forall i = 1, \dots, q$, los coeficientes del modelo.

Podemos emplear una notación polinómica usando el operador de retardos B obteniendo:

$$X_t = (1 - \theta_1 B - \theta_2 B^2 - \cdots - \theta_q B^q) \varepsilon_t = \theta(B) \varepsilon_t \quad (2.9)$$

siendo $\theta(B)$ el polinomio característico del proceso $MA(q)$. A la ecuación $\theta(B) = 0$ se le conoce como la ecuación característica del modelo.

Aplicando las definiciones de los momentos (definición 4) en el proceso (definición 8) podemos calcular de forma analítica todos los momentos para este proceso y comprobamos que los MA puros son siempre estacionarios. Para una descripción detallada de los resultados véase el apartado A.1 presente en el anexo.

Definición 9. Sea ε_t un proceso de ruido blanco. Se dice que X_t es un proceso autorregresivo de orden p , denotado $AR(p)$, si se escribe:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t \quad (2.10)$$

siendo ϕ_i , $\forall i = 1, \dots, p$, los coeficientes del modelo.

Empleando notación polinómica:

$$(1 - \phi_1 B - \phi_2 B^2 - \cdots - \phi_p B^p) X_t = \varepsilon_t \quad \Rightarrow \quad \phi(B) X_t = \varepsilon_t \quad (2.11)$$

siendo $\phi(B)$ el polinomio característico del proceso $AR(p)$.

Estacionariedad de los procesos *ARMA*

Para analizar la estacionariedad de los procesos *AR* y *MA*, es conveniente establecer primero la relación entre ambos. Sea un proceso $AR(1)$ donde iteramos tal que:

$$X_t = \phi X_{t-1} + \varepsilon_t \quad \Rightarrow \quad X_t = \phi(\phi X_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \quad \Rightarrow \quad X_t = \varepsilon_t + \phi \varepsilon_{t-1} + \phi^2 \varepsilon_{t-2} + \cdots$$

obteniendo la relación:

$$X_t = \sum_{K=0}^{\infty} (\phi B)^K \varepsilon_t \quad (2.12)$$

Si $|\phi| < 1$ aseguramos la convergencia de la serie y podemos escribirla como una serie geométrica tal que:

$$X_t = \frac{1}{1 - \phi B} \varepsilon_t \quad \Rightarrow \quad X_t = \frac{1}{\phi(B)} \varepsilon_t \quad (2.13)$$

con $\phi(B) = 1 - \phi B$.

La condición $|\phi| < 1$ es equivalente a que todas las raíces del polinomio característico $\phi(B)$ estén fuera del círculo unidad. Si escribimos el proceso $AR(1)$ como, $\phi(B) X_t = \varepsilon_t$, entonces, si se cumple que $|\phi| < 1$ las raíces $B = \frac{1}{\phi}$ se encuentran fuera del círculo unidad. Así pues, podemos expresar un modelo $AR(1)$ como un proceso $MA(\infty)$. Por otra parte, un proceso $AR(p)$ será estacionario si se cumple la condición de que las raíces de la ecuación $\phi(B) = 0$ se encuentran fuera del círculo unidad.

De manera análoga en un $MA(1)$ dado por $X_t = (1 - \theta B) \varepsilon_t$, podemos expresar la relación $AR(\infty) = MA(1)$, si $|\theta| < 1$ se dice entonces que el proceso es invertible. Es por esto por lo

que un proceso X_t será invertible si se puede expresar en función de su propio pasado, por tanto, todos los procesos AR puros son invertibles. De igual modo, para un $MA(q)$, si las raíces de la ecuación $\theta(B) = 0$ se encuentran fuera del círculo unidad.

Con los procesos más básicos definidos surge ahora una cuestión natural a cerca de la combinación de ambos. Con el objetivo de intentar explicar la influencia de valores y errores pasados conseguimos definir un modelo mixto.

Definición 10. *Se dice que un proceso $\{X_t\}$ es un proceso $ARMA(p, q)$ (mixto), si se escribe de la siguiente forma:*

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q} \quad \Rightarrow \quad \phi(B)X_t = \theta(B)\varepsilon_t \quad (2.14)$$

Los modelos $ARMA(p, q)$ son estacionarios si la parte AR cumple la condición de estacionariedad. Si esto no ocurre, esta clase de procesos se extiende a los modelos $ARIMA(p, d, q)$.

Definición 11. *$\{X_t\}$ es un proceso autorregresivo integrado de orden d de medias móviles, $ARIMA(p, d, q)$, si el proceso $W_t = \nabla^d X_t$ es un proceso $ARMA(p, q)$. Cabe destacar que el parámetro d se refiere al número de diferencias a aplicar para conseguir que el proceso W_t sea estacionario en media.*

Entonces, aplicando notación polinómica:

$$\phi(B)\nabla^d X_t = \theta(B)\varepsilon_t \quad \text{o bien} \quad \phi(B)W_t = \theta(B)\varepsilon_t \quad (2.15)$$

donde W_t es el proceso transformado y estacionario.

2.1.4. Procesos SARIMA

La correlación periódicas entre las distintas mediciones temporales (por ejemplo, días o meses), son muy frecuentes en el análisis de la evolución de muchos objetos de estudio. Tenemos así la influencia del periodo estacional s que representa el número de mediciones tomadas en un año, periodo donde aparece la estacionalidad. Si los datos son tomados mensualmente, entonces $s = 12$ y si son diarios $s = 7$. Así, los modelos estacionales parten del marco teórico básico de los modelos $ARIMA$, pero complementándolos por una componente estacional donde se espera una dependencia entre X_t y X_{t-s} , haciendo referencia $\hat{s}$ a los múltiplos de s . Al añadir esta componente periódica haremos distinción entre la parte regular

y estacional del modelo. Tenemos así, dos posibilidades de tratar estos modelos; aquellos denominados puramente estacionales, que representan un modelo con solo parte estacional y en segundo lugar, estacionales multiplicativos, que combinan las dos ya mencionadas: regular y estacional.

Modelos puramente estacionales

Estos modelos son aquellos que solo dependen de la parte estacional. Al igual que en el apartado anterior se estudiará la influencia de los errores y valores en instantes anteriores.

Definición 12. Sea ε_t un proceso de ruido blanco. Se dice que $\{X_t\}$ es un proceso de media móvil estacional de orden Q , denotado por $SMA(Q)_s$, si se escribe, empleando notación polinómica:

$$X_t = (1 - \Theta_1 B^s - \Theta_2 B^{2s} - \dots - \Theta_Q B^{Qs}) \varepsilon_t \Rightarrow X_t = \Theta(B^s) \varepsilon_t \quad (2.16)$$

siendo $\Theta(B^s)$ el polinomio característico del proceso $SMA(Q)_s$.

Definición 13. Sea ε_t un proceso de ruido blanco. Se dice que $\{X_t\}$ es un proceso autorregresivo estacional de orden P , denotado por $SAR(P)_s$, si se escribe, en notación polinómica:

$$(1 - \Phi_1 B^s - \Phi_2 B^{2s} - \dots - \Phi_P B^{Ps}) X_t = \varepsilon_t \Rightarrow \Phi(B^s) X_t = \varepsilon_t \quad (2.17)$$

siendo $\Phi(B^s)$ el polinomio característico del proceso $SAR(P)_s$.

Estacionariedad de los modelos puramente estacionales

Al igual que con sus homólogos regulares, el modelo SMA resulta invertible si las raíces de la ecuación, $\Theta(B^s) = 0$, son, en módulo, mayores que 1 y el modelo SAR es estacionario si las raíces del polinomio característico, $\Phi(B^s) = 0$, son, en módulo, mayores que 1.

De nuevo la cuestión de unificar ambos modelos en uno solo propone una variante adicional, un modelo mixto estacional.

Definición 14. La combinación del modelo SAR y SMA nos proporciona un modelo conocido como $SARMA$. Sea ε_t un proceso de ruido blanco, se dice que $\{X_t\}$ es un proceso autorregresivo de media móvil estacional de orden (P, Q) , denotado $SARMA(P, Q)_s$ si se escribe, empleando

la formulación polinómica :

$$\Phi(B^s)X_t = \Theta(B^s)\varepsilon_t \quad (2.18)$$

donde $\Phi(B^s)$ y $\Theta(B^s)$ son los polinomios característicos del proceso autorregresivo y de medias móviles estacionales respectivamente.

Definición 15. Los modelos que no presentan estacionariedad pueden corregirse aplicando la diferenciación, en este caso estacional. De esta manera, si $\{X_t\}$ es un proceso no estacionario, podemos aplicar $W_t = \nabla_s^D X_t$ que es un proceso $SARMA(P, Q)$ estacionario. Se dice entonces, que $\{X_t\}$ es un proceso $SARIMA(P, D, Q)_s$ que se puede representar de la siguiente forma polinómica como:

$$\Phi(B^s)\nabla_s^D X_t = \Theta(B^s)\varepsilon_t \quad \text{o bien} \quad \Phi(B^s)W_t = \Theta(B^s)\varepsilon_t$$

donde $\Phi(B^s)$ y $\Theta(B^s)$ son los polinomios característicos del proceso autorregresivo y de medias móviles estacionales respectivamente.

Estacionariedad de los modelos mixtos estacionales

La notación polinómica facilita la comparación con los modelos regulares, pues al igual que estos, si todas las ecuaciones de la parte autorregresiva, $\phi(B) = 0$ y $\Phi(B^s) = 0$, presentan raíces fuera del círculo unidad conseguiremos estacionariedad.

Hasta el momento hemos tratado modelos que tratan la estacionalidad por separado a los modelos regulares. Unificando todos los modelos en uno, que trate parte regular y parte estacional, obtenemos dos posibilidades; modelos $SARMA(p, q)x(P, Q)_s$ y modelos $SARMA(p, d, q)x(P, D, Q)_s$. Ambos modelos presentan las mismas condiciones y su única diferencia es la presencia de diferenciaciones regulares o estacionales.

Definición 16. Sea ε_t un proceso de ruido blanco, se dice que $\{X_t\}$ es un proceso autorregresivo de media móvil estacional multiplicativo de orden $(p, q)x(P, Q)_s$, denotado por $SARMA(p, q)x(P, Q)_s$ si se escribe:

$$\phi(B)\Phi(B^s)X_t = \theta(B)\Theta(B^s)\varepsilon_t \quad (2.19)$$

Sobre este modelo añadimos las diferenciaciones, regulares o estacionales, necesarias para convertir el proceso en estacionario.

Definición 17. Sea ε_t un proceso de ruido blanco. Si el proceso X_t no es estacionario, pero el proceso $W_t = \nabla^d \nabla_s^D X_t$ si lo es, diremos que $\{X_t\}$ es autorregresivo integrado de media móvil estacional multiplicativo, denotado por, $SARIMA(p, d, q)X(P, D, Q)_s$ si se escribe en notación polinómica como:

$$\phi(B)\Phi(B^s)\nabla^d\nabla_s^D X_t = \theta(B)\Theta(B^s)\varepsilon_t \quad \text{o bien} \quad \phi(B)\Phi(B^s)W_t = \theta(B)\Theta(B^s)\varepsilon_t \quad (2.20)$$

Estos modelos son los más completos, pues pueden conseguir explicar tanto influencias estacionales como regulares de errores y valores reales pasados.

2.1.5. Modelos multivariantes

Hasta el momento tan solo hemos tratado influencia de errores y valores reales de la serie pasados. En la práctica puede ser necesario incorporar la influencia adicional de variables exógenas en el modelo. Surgen entonces los modelos autorregresivos integrados de medias móviles con variables exógenas, *ARIMAX*. Al igual que con los modelos básicos, contamos con la variante estacional, *SARIMAX*. Estos modelos han sido estudiados por numerosos autores desde un punto de vista práctico. Dos de los más destacados son *Rob J Hyndman* y *George Athanasopoulos*⁶, quienes han aportado una visión mayoritariamente académica y aplicada con *RStudio*.

Modelos ARIMAX y SARIMAX

Como ya se ha visto, el modelo *SARIMA* es el más completo, pues incluye información de errores y valores reales pasados de forma regular y estacional. La extensión de variables exógenas completa el modelo. Para incluir estas variables al modelo, se tratará como un modelo de regresión lineal donde el error seguirá un modelo, en este caso, *SARIMA*.

Definición 18. Sea ε_t un proceso de ruido blanco. Se dice que $\{X_t\}$ es un proceso $SARIMA(p, d, q)x(P, D, Q)_s$, tal que de forma polinómica se escribe:

$$\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D X_t = \theta(B)\Theta(B^s)\varepsilon_t \Rightarrow X_t = \frac{\theta(B)\Theta(B^s)}{\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D} \varepsilon_t$$

Diremos que $\{Y_t\}$ es un proceso $SARIMAX(p, d, q)x(P, D, Q)_s$ con n variables explicativas

si se escribe:

$$Y_t = \frac{\theta(B)\Theta(B^s)}{\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D} \cdot \varepsilon_t + \beta_1 Z_1(t) + \dots + \beta_n Z_n(t) \quad (2.21)$$

donde β_i son los coeficientes para las variables $Z_i \quad \forall i = 1, \dots, n$.

2.1.6. Tratamiento de intervenciones y *outliers*

En el modelo establecido, incluiremos posibles intervenciones, es decir, variables que expliquen cambios o impactos en la serie. Las más comunes son intervenciones de calendario, esto es, aquellas relacionadas con ocurrencias temporales como por ejemplo las festividades. Para nuestro interés, centrado en el estudio de series mensuales, vamos a definir tres variables explicativas: días hábiles, denotada por *laborables(t)*; Semana Santa, denotada por *semanaSanta(t)* (abreviaremos por *sS(t)* para mayor legibilidad) y año bisiesto, denotada por *bisiesto(t)*. En primer lugar, la variable *laborables* se calcula para conocer el efecto de los días hábiles netos en la serie. Para su cálculo, se excluyen tanto las festividades nacionales como las festividades autonómicas, dependiendo del ámbito territorial seleccionado. En segundo lugar, se hace uso de la variable *semanaSanta(t)*, que determina la cantidad de días festivos atribuidos a la Semana Santa en cada mes. Por último, la variable bisiesto, donde se calcula si el año en que se toma la predicción es bisiesto y, de ser así, se añade la influencia de un día adicional en el mes de febrero. De esta forma calcularemos para una serie con datos mensuales:

- $\text{laboral}(t) = 1 - n^\circ \text{ de s\u00e1bados en } t - n^\circ \text{ de domingos en } t$
- $\text{sS}(t) = \begin{cases} j, & \text{si } t \text{ tiene } j \text{ d\u00edas de Semana Santa} \quad \forall j = 1, \dots, 5; \\ 0, & \text{en otro caso.} \end{cases}$
- $\text{bisiesto}(t) = \begin{cases} 1, & \text{si } t = \text{febrero y a\u00f1o bisiesto}; \\ 0, & \text{en otro caso.} \end{cases}$

Para el an\u00e1lisis de datos at\u00edpicos u *outliers* se busca eliminar el efecto de datos que nuestro modelo no ha podido explicar. Estudiaremos dos de los tipos m\u00e1s comunes de *outliers*, los aditivos (*AO*, *additive outlier*) y los cambios de nivel (*LS*, *level shift*). Los primeros consisten en impactos puntuales, mientras que los de cambio de nivel, suponen un cambio brusco, mantenido a lo largo del tiempo. Para reflejar el efecto de estos *outliers* se emplean las siguientes variables:

$$AO_{t_0}(t) = \begin{cases} 1, & \text{si } t = t_0; \\ 0, & \text{en otro caso.} \end{cases} \quad y \quad LS_{t_0}(t) = \begin{cases} 1, & \text{si } t \geq t_0; \\ 0, & \text{en otro caso.} \end{cases} \quad (2.22)$$

2.2. Metodología *Box-Jenkins*

Los principales autores de referencia en el estudio de series temporales son los estadísticos *George E. P. Box* y *Gwilym M. Jenkins*³, cuyo trabajo en esta disciplina dio lugar a la metodología de referencia. Este proceso consiste en un método iterativo dividido en cuatro pasos clave. Un requisito para poder ejecutar este algoritmo es la estacionariedad de la serie. Para verificarla en una serie temporal, se puede utilizar la prueba de *Dickey-Fuller* aumentada (ADF), la cual permite evaluar la existencia de raíces unitarias en el proceso. Esta prueba, propuesta por *David A. Dickey* y *Wayne A. Fuller*⁵, plantea un contraste de hipótesis donde la hipótesis nula establece la presencia de una raíz unitaria, lo que implica no estacionariedad. Rechazar esta hipótesis nos permitiría concluir que la serie es estacionaria.




Figura 2.1: Diagrama del algoritmo de Box-Jenkins elaborado en el artículo *Rainfall Forecast for the Municipality of Vitória de Santo Antão – PE*⁴

2.2.1. Identificación

El primer paso de identificación del modelo se lleva a cabo mediante las funciones de autocorrelación simple, en adelante *FAS*, y parcial, *FAP*. El coeficiente ρ_h determina la autocorrelación simple de orden h , mientras que r_h consiste en el h -ésimo valor de la función de autocorrelación parcial, el cual representa la relación que existe entre observaciones separadas h períodos, eliminando el efecto de los valores intermedios. Esta se calcula mediante la estimación de los parámetros $\phi_{h,h}$ de un procesos $AR(h)$ donde h recorre todos los posibles ordenes del proceso AR . Se pueden utilizar las ecuaciones de *Yule-Walker*¹⁰ para acelerar este cálculo. Se puede demostrar que la *FAP* identifica el orden de un proceso AR puro mientras que la *FAS* determina el del proceso MA puro.

Con estos valores calculados, se realiza inferencia mediante un intervalo de confianza a través del cual se determina si estas autocorrelaciones son o no significativamente distintas de cero. Para el caso de la *FAP* el intervalo de confianza viene dado por $[-\frac{2}{\sqrt{n}}, \frac{2}{\sqrt{n}}]$ siendo n el tamaño de la muestra. Por otro lado, para la *FAS* se puede demostrar que $\rho_h \sim \mathcal{N}(0, \sqrt{Var(\rho_h)})$, por lo que el intervalo de confianza será $[-2\sqrt{Var(\hat{r}_h)}, 2\sqrt{Var(\hat{r}_h)}]$ siendo $Var(\hat{r}_k) = \frac{1}{n} \cdot 1 + 2 \sum_{k=1}^{h-1} r_k^2$.

Con las funciones de autocorrelación ya determinadas se procede a establecer una primera aproximación del orden del modelo en función de los valores significativos de ambas gráficas.

2.2.2. Estimación

Una vez identificado el modelo, tenemos que determinar el valor estimado para los parámetros. Para ello se puede emplear el método de mínimos cuadrados, es decir, para un proceso general $SARIMA(p,d,q)x(P,D,Q)$, tenemos que minimizar la expresión:

$$S = \sum_{t=p+1}^n e_t^2 = \sum_{t=p+1}^n \left(\frac{\phi(B)\Phi(B^s)}{\theta(B)\Theta(B^s)(1-B)^d(1-B^s)^D} X_t \right)^2 \quad (2.23)$$

Para ello es necesario aplicar métodos de aproximación numérica, pues al plantear las ecuaciones aparecen relaciones no lineales entre los parámetros.

2.2.3. Validación

Una vez contamos con una propuesta de modelo, tenemos que validar si el proceso residual cumple las hipótesis necesarias de ruido blanco (véase la definición 7). Para la

comprobación de estas tres condiciones emplearemos los *test* de hipótesis correspondientes. Para la verificación de la incorrelación de los residuos del modelo emplearemos el contraste de *Ljung-Box*. Así, si obtenemos un *p-valor* mayor que 0,05 no tendremos evidencias suficientes para rechazar H_0 : Los residuos están incorrelados. De igual modo procedemos con el contraste de *Breusch-Pagan* para la homocedasticidad. La condición de normalidad no es necesaria, pero si deseable, para comprobarla haremos uso de la prueba de *Lilliefors*. Ambas hipótesis nulas contemplan la existencia de homocedasticidad y normalidad respectivamente.

2.2.4. Predicción

Validado el modelo, estamos en disposición de realizar predicciones a futuro. En primer lugar, supongamos un proceso $SARIMA(p, d, q)x(P, D, Q)_s$, de forma que escribimos:

$$\begin{aligned} \phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D X_t &= \theta(b)\Theta(b^s)\varepsilon_t \quad \Rightarrow \quad X_t = \frac{\theta(b)\Theta(b^s)}{\phi(B)\Phi(B^s)(1-B)^d(1-B^s)^D} \varepsilon_t \\ &\Rightarrow \quad X_t = \psi(B)\varepsilon_t \\ &\Rightarrow \quad X_t = \left(1 + \sum_{i=1}^{\infty} \psi_i B^i\right) \varepsilon_t \end{aligned} \quad (2.24)$$

Entonces para determinar la predicción en el instante $k > n$ empleamos $I = k - n$ tal que:

$$X_n(I) = \psi_I \varepsilon_n + \psi_{I+1} \varepsilon_{n-1} + \dots$$

Así, llegamos a la expresión de la predicción puntual:

$$\hat{X}_n(I) = \hat{\psi}_I e_n + \hat{\psi}_{I+1} e_{n-1} + \dots \quad \text{siendo} \quad e_j(I) = X_j - \hat{X}_j(I) \quad \forall j = 1, \dots, n$$

A partir de estas predicciones somos capaces de desarrollar un intervalo para estas predicciones, esto es, un intervalo de predicción. Así, para el nivel de significatividad α , podemos determinar el intervalo de predicción tal que:

$$IP_{(1-\alpha)100\%}(X_j(I)) = \hat{X}_j(I) \pm z_{\alpha/2} \sqrt{\hat{Var}(e_j(I))} \quad (2.25)$$

2.3. Estimaciones masivas

El contexto actual de análisis de datos premia el tratamiento de los grandes volúmenes de información. Las técnicas de estudio básicas se han visto obligadas a evolucionar para manejar de manera sencilla tales cantidades de datos. En series temporales la adaptación más notoria es las técnicas de estimación masiva. Partiendo de un sistema jerárquico, donde la información mantiene una determinada relación, se ejecutan procesos que mejoran la calidad de los resultados obtenidos. Existen diferentes metodologías en función el objetivo deseado que veremos a continuación. Para el desarrollo de este apartado, la visión aplicada a problemas prácticos de *Rob J Hyndman* y *George Athanasopoulos*⁶ aportan gran valor al estudio de los conceptos teóricos.

2.3.1. Modelos jerárquicos

Un sistema jerárquico consiste en una división de la información total en k diferentes niveles relacionados entre sí. La desagregación se realiza conforme a una estructura lógica de dependencia. Un caso habitual es la división territorial, donde el conjunto nacional se puede segmentar en niveles dependientes como el autonómico y este a su vez en el provincial (véase la figura 2.2 donde se presenta un sistema de dos niveles). De esta forma tenemos la relación directa entre las diferentes capas del sistema. Nótese que el número de divisiones en cada nivel no tiene por qué ser el mismo en todas las capas.




Figura 2.2: Sistema jerárquico general de dos niveles, elaborado en *Introduction to Hierarchical Time Series*¹

Para tratar con este tipo de modelos vamos a presentar la notación más habitual. Partimos de la serie total en la que, una observación en el instante temporal t vendrá denotada por x_t .

Para referirnos a los niveles inferiores haremos uso de un subíndice adicional. Sin embargo, la cantidad de niveles y subniveles dificultan la comprensión, por lo que este índice adicional será el nombre de cada elemento de la estructura. Así, para referirnos a las observaciones del elemento A y del primer nivel denotaremos $x_{A,t}$ y para el segundo nivel $x_{A1,t}, x_{A2,t}$. De forma análoga denotaríamos las observaciones de los elementos B . Al ser divisiones de los datos totales obtenemos que, para este pequeño ejemplo:

$$x_{A,t} = x_{A1,t} + x_{A2,t}$$

$$x_{B,t} = x_{B1,t} + x_{B2,t}$$

$$x_t = x_{A,t} + x_{B,t} = (x_{A1,t} + x_{A2,t}) + (x_{B1,t} + x_{B2,t})$$

Podemos ver que la estructura jerárquica se mantiene para cada nivel, pues la relación de los elementos A y B con respecto del total es la misma que la de los elementos $A_j \quad \forall j = 1, 2$ con el elemento A . De forma generalizada y matricialmente obtendríamos:

$$\begin{bmatrix} x_t \\ x_{A,t} \\ x_{B,t} \\ x_{A1,t} \\ x_{A2,t} \\ x_{B1,t} \\ x_{B2,t} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_{A1,t} \\ x_{A2,t} \\ x_{B1,t} \\ x_{B2,t} \end{bmatrix}.$$

Para un caso general con k niveles y j subniveles, contaríamos con una matriz $S \in M_{j \times (k+1)}$, tal que:

$$x_t = Sb_t.$$

Con la notación ya definida vamos ahora a plantear las diferentes estrategias disponibles con las que abordar cuestiones de predicción. El algoritmo consistirá en predecir los elementos deseados y relacionar los niveles según la estructura jerárquica.

2.3.2. Estimación *Bottom-up*

Esta metodología supone un acercamiento a la cuestión de predicción sobre la serie de más alto nivel de la jerarquía. Ya hemos comprobado que la suma de los valores observados en cada nivel tiene como resultado el valor de la capa superior. Gracias a esto, si somos capaces de predecir los niveles inferiores de la estructura jerárquica, aplicando una simple suma de todos los términos predichos obtendríamos el valor total de nuestra serie. Esto es, sea $\hat{x}_{k,h}$, la predicción para el nivel k en el horizonte de predicción h , tendríamos la relación:

$$\hat{x}_h = S\hat{b}_h$$

De esta forma matricial estaríamos asegurando, para todos los niveles, que la suma de las predicciones de cada nivel tiene como resultado la predicción del elemento que las relaciona en la capa superior.

2.3.3. Estimación *Top-down*

En ocasiones el objetivo es contrario al anterior, y partiendo de un nivel superior se quiere predecir el valor de alguna capa inferior. En este caso contamos con una cuestión adicional, que es el reparto por nivel. Para solventarlo se añade un vector de proporciones p cuya función consiste en dividir el valor de la estimación total en los diferentes niveles en los que se divide. De esta forma las predicciones para una capa inferior vendrían dadas por:

$$\hat{b}_h = p\hat{x}_h$$

Las proporciones reales de cada estimación no suelen ser conocidas en casos prácticos. Es por esto por lo que se pueden estimar de varias formas. En primer lugar, haciendo uso de proporciones históricas, esto es, a partir de datos pasados obtener la relación proporcional entre los diferentes niveles, de esta forma calcularíamos el vector p como:

$$p_j = \frac{1}{T} \sum_{t=1}^T \frac{x_{j,t}}{x_t} \quad \forall t = 1, \dots, T$$

Estas proporciones otorgan una estimación adecuada. En el caso que nos ocupa, y para una aplicación práctica posterior, haremos uso del cálculo de proporciones mediante las

predicciones del nivel que queremos estimar. De forma que obtendremos el vector p para el nivel k como:

$$p_j = \frac{1}{T} \sum_{t=1}^T \frac{\hat{x}_{kj,t}}{\hat{x}_t} \quad \forall t = 1, \dots, T \quad \forall j = 1, \dots, J$$

siendo J el número de elementos en el nivel k -ésimo. Por tanto, la estimación en el horizonte h para cada elemento j del nivel k de nuestro sistema queda recogido en la siguiente ecuación:

$$\hat{b}_{kj,h} = p_j \hat{x}_h \quad \forall j = 1, \dots, J$$

2.3.4. Estimación *Middle-out*

En las metodologías anteriores siempre se toma una dirección; desagregar predicciones hacia niveles inferiores o sumarlas hacia niveles superiores. Sin embargo, existen situaciones donde partimos de un nivel intermedio y el objetivo puede ser tanto predecir valores de capas superiores como de capas inferiores. En estos casos, tan solo deberemos tomar como referencia la capa intermedia y aplicar las técnicas *Bottom-up* para predecir valores superiores y *Top-down* para predecir niveles inferiores. De esta forma cubriremos todas las posibilidades de estimación dentro del sistema jerárquico.

2.4. Función de búsqueda

Para la implementación de la función de búsqueda del mejor modelo, se han automatizado los pasos de un ajuste manual. Esta función toma como parámetros: los datos, el límite superior de los ordenes del proceso *SARIMA*, la frecuencia de la serie, una variable binaria para identificar posibles variables explicativas y el nivel de significatividad de los contrastes implicados. De esta forma seguiremos un algoritmo donde se calcularán todas las variables explicativas necesarias y las combinaciones de ordenes posibles; se aplicará la mejor transformación y se iterará sobre todas las combinaciones para encontrar el modelo con mejor valor de una métrica de bondad de ajuste sobre el entrenamiento. Respecto a esta métrica se seguirán dos criterios: la comparación por el criterio *AIC*, equivalente a la función *auto.arima* de *RStudio* y de forma adicional la comparación por el error *MAPE*. Asimismo, para cada posible modelo se comprueban todas las hipótesis de significatividad de los parámetros y variables explicativas, así como el cumplimiento de las hipótesis del modelo. Si el modelo no cumple con la validez de las hipótesis necesarias o con la significatividad

de los parámetros, este se descarta. Establecido el modelo final, se calcula el error *MAPE* en cada instante temporal. El siguiente algoritmo muestra el pseudocódigo asociado a esta función.

Entrada: Serie de tiempo, parámetros máximos, α , uso de variables explicativas

Salida : Mejor modelo según MAPE y AIC, predicciones

Inicializar rangos de p, d, q, P, D, Q;

Generar combinaciones de parámetros;

Dividir datos en entrenamiento y prueba;

Calcular lambda óptimo con Box-Cox;

Transformar datos según lambda;

if *usar explicativas* **then**

 | Calcular variables calendario para entrenamiento;

end

foreach *combinación válida* **do**

 Ajustar modelo ARIMA (con o sin explicativas);

if *modelo no válido o coeficientes no significativos* **then**

 | siguiente combinación;

end

 Validar supuestos: independencia, homocedasticidad, normalidad;

if *algún test no se cumple* **then**

 | siguiente combinación;

end

 Calcular MAPE y AIC del modelo;

 Actualizar mejor modelo si mejora;

end

if *no hay modelo válido* **then**

 | **return** *NULL*

end

Generar predicciones con ambos modelos;

Destransformar según lambda;

Calcular errores MAPE punto a punto;

return *Modelos, errores y predicciones*.

Algoritmo 1: Pseudocódigo para la función de búsqueda

Capítulo 3

Aplicación práctica

Una vez establecida la base teórica sobre la que trabajar, realizaremos un estudio de un caso real en el que compararemos las diferentes técnicas de estimación para un problema concreto: la compraventa de viviendas en España tanto a nivel de comunidades autónomas como de provincias. Esta relación territorial marcará el sistema jerárquico. El ajuste de la serie nacional se realizará de forma manual y se contrastará con los resultados obtenidos a partir de los cálculos automáticos para las series autonómicas y provinciales. El principal objetivo de este estudio es comparar el impacto en las predicciones mediante las estrategias *Bottom-Up*, *Top-down*, *Middle-Out* y el ajuste manual de la serie.

Una de las cuestiones que se llevará a cabo en paralelo es la comparación entre diferentes formas de cálculo de los modelos automáticos. Los entornos de programación ya incluyen códigos con esta funcionalidad, pero donde no es necesario el cumplimiento de las hipótesis para un ajuste adecuado. En este aspecto, se empleará una función de búsqueda del mejor modelo para cada serie en función de dos criterios. El primero de ellos es el criterio basado en la información de *Akaike* del modelo, *AIC* que se comparará con la función *auto.arima*. Adicionalmente emplearemos la evaluación del error absoluto medio porcentual del modelo, *MAPE*, escogiendo aquel con menor valor respecto de dicha métrica en la muestra de entrenamiento del modelo (ver el apartado 2.4).

Se pondrá entonces de manifiesto, para este caso concreto, qué criterio y estrategia proporciona mejores resultados. Para cualquier consulta relacionada con el código (véase el Anexo B)

3.1. Descripción del procedimiento

Para abordar todos estos contenidos, primero realizaremos el ajuste manual de la serie nacional, asegurándonos del cumplimiento de las hipótesis del modelo, la significatividad y el empleo de variables explicativas. Con el modelo y las predicciones establecidas, procederemos con el ajuste automático de las series autonómicas y provinciales. Finalmente, compararemos las estrategias y modelos propuestos para determinar el mejor camino para cada caso concreto.

3.2. Conjunto de datos

La información utilizada ha sido extraída del portal INEbase del Instituto Nacional de Estadística (INE)⁷ con enlace "<https://www.ine.es/jaxiT3/Tabla.htm?t=6150>". Las características de estos datos presentan la estructura jerárquica requerida para el estudio, contando con información a nivel nacional, autonómica y provincial (ver figura A.1 presente en el anexo). Los primeros registros del conjunto, tomados mensualmente, datan del año 2009 y finalizan en 2019. Los datos para cada comunidad autónoma y provincia cuentan con las mismas características.

3.3. Análisis de la serie




Figura 3.1: *Gráfico de evolución de la compraventa de viviendas a nivel nacional.*

Como se puede observar, la serie presenta diversas particularidades que revelan una tendencia y una variabilidad notable (ver figura 3.1). Con el fin de determinar si es estacionaria en media y varianza, se emplearán pruebas estadísticas específicas. Estas nos permitirán proceder con el ajuste de la serie sin necesidad de aplicar diferenciaciones o identificaciones de valores atípicos previos. El objetivo consiste en, a partir del análisis de las funciones de autocorrelación simple y parcial, ser capaces de determinar el orden de los parámetros de los que depende el modelo.

3.3.1. Consideraciones previas

Antes de proceder con el ajuste del modelo, se dividirá el conjunto de datos en dos subconjuntos: entrenamiento y prueba. La asignación de los datos se realizará de acuerdo con una proporción 80/20, donde el 80 % de los datos se destinará al conjunto de entrenamiento y el 20 % restante al conjunto de prueba. Esta división se realiza siguiendo la coherencia temporal exigida en este contexto y cuenta con datos de los primeros ocho años para el entrenamiento y los dos restantes para la fase de prueba. Contamos entonces con suficientes datos para aplicar la metodología *Box-Jenkins* (véase apartado 2.2).

A la hora de validar los modelos haremos uso de las pruebas de hipótesis con los paquetes correspondientes para cada caso. Cabe destacar que consideramos $\alpha = 0,05$ como el nivel de significatividad para todas las hipótesis. Se emplearán la prueba de *Ljung-Box*, para el estudio de la incorrelación; *Breusch-Pagan*, para la homocedasticidad y *Lilliefors*, para la normalidad. El test de *Ljung-Box* se ejecutará para los distintos retardos del modelo esperando que todos los p-valores sean mayores que el nivel de significatividad.

Otro de los factores de interés es la inclusión de variables explicativas. En este caso particular, la compraventa de viviendas se ve afectada por la disposición de los festivos, años bisiestos y los periodos vacacionales como Semana Santa. Para analizar estas variables explicativas en los diferentes modelos, hablaremos de significatividad de la variable y de signo coherente con el negocio, es decir, si la aportación de la variable es compatible con la lógica del problema. Para este caso, la variable explicativa *bisiesto* debería aumentar la compraventa de casas al añadir un día más al calendario y la variable *semanaSanta* debería disminuir el numero total. La variable *laboral* considera el impacto por meses, unidad temporal de los datos, de un día laborable adicional, es por esto, por lo que esperamos que esta variable contribuya positivamente en la compraventa de viviendas. Incluiremos estas tres variables

como parte de nuestro modelo para proporcionar una solución más ajustada.

3.3.2. Ajuste manual de la serie

Estudio de la estacionariedad de la serie

Antes de realizar cualquier ajuste, es fundamental verificar la estacionariedad de la serie. El primer paso en este proceso consiste en analizar la estacionariedad en varianza, para lo cual evaluaremos la necesidad de aplicar una transformación a los datos. Siguiendo las transformaciones más habituales, consideraremos dos principales: la transformación logarítmica, que es la más común, y la transformación por raíz cuadrada. Para determinar la más apropiada evaluaremos el logaritmo de la función de verosimilitud bajo las dos transformaciones mencionadas en el capítulo 2.1.2 y lo compararemos con el valor obtenido si no se emplea ninguna transformación. En el caso de esta serie, el resultado indica que la transformación logarítmica es la más adecuada, al ser la que maximiza el logaritmo de la función de verosimilitud (ver cuadro 3.1).

	$\lambda = 0$	$\lambda = 0,5$	$\lambda = 1$
Logaritmo de la función de verosimilitud	-73.59851	-74.55416	-76.46185

Cuadro 3.1: Log-verosimilitud para distintos valores de λ

El siguiente paso será evaluar la estacionariedad en media. Para ello, se empleará el test de *Dickey-Fuller* aumentado (*ADF*) para tres modelos, cuyos resultados se presentan a continuación:

Test	Sin Intercepto ($X_t = \phi X_{t-1}$)	Con Intercepto ($X_t = \phi X_{t-1} + \mu$)	Con Intercepto y Tendencia ($X_t = \phi X_{t-1} + \mu + \gamma \cdot t$)
p valor	0.9407163957	0.0009442914	0.0009941263

Cuadro 3.2: Resultados del Test *ADF* para diferentes condiciones

Como se puede apreciar en el cuadro 3.2, los valores obtenidos en el test de raíces unitarias muestran un *p-valor* bajo, lo que conduce a rechazar, en principio, la necesidad de diferenciar la serie para un modelo con intercepto. Entonces, para el primer acercamiento a la serie se procederá sin aplicar diferenciación a los datos y con la transformación por logaritmo ya mencionada.

Determinación de los coeficientes del modelo

Una vez logradas las condiciones de estacionariedad para nuestros datos, comenzamos determinando manualmente los coeficientes del modelo ajustado a la serie nacional. En primer lugar, el objetivo será decidir el orden de los parámetros iniciales apoyándonos en las funciones de autocorrelación simple y parcial de nuestros datos transformados. En este caso, podemos apreciar que el gráfico de la *FAS* (ver figura 3.2) presenta multitud de valores significativos lo que evidencia un orden infinito del proceso de medias móviles, MA , que se relaciona con un proceso autorregresivo de parámetro p , de la forma $MA(\infty) = AR(p)$ (véase 2.1.3). Por otro lado, el gráfico de *FAP* (ver figura 3.3) nos lleva a concretar en 1 el valor de p , al ser la primera autocorrelación la de mayor valor.




Figura 3.2: *Función de Autocorrelación Simple de los datos*




Figura 3.3: *Función de Autocorrelación Parcial de los datos*

Bajo estas consideraciones proponemos entonces un modelo $ARMA(1,0)$. Este presenta el coeficiente autorregresivo significativo y una estimación lejana a 1, lo que nos indica que, por el momento, no parece necesario aplicar una diferenciación regular (ver cuadro 3.3).

Variable	Estimate	Std. Error	z value	Pr(> z)
ar1	0.674245	0.070302	9.5907	<2.2e-16 ***
intercepto	10.341072	0.040636	254.4787	<2.2e-16 ***

Cuadro 3.3: *Coefficientes del modelo $ARMA(1,0)$*

Contamos entonces con un modelo $ARMA(1,0)$ con los parámetros estimados del cuadro 3.3, es decir, $X_t = 10,341072 + 0,674245 \cdot X_{t-1} + \varepsilon_t$.

Para continuar con el ajuste vamos a estudiar el comportamiento de los residuos del modelo. Observamos que, tanto en la *FAS* como en la *FAP* de los residuos (ver figuras 3.4 y 3.5) aparece un patrón de repetición en los retardos equivalentes al tiempo 12, 24 y 36 en el caso de la *FAS* y el retardo 12 en la *FAP*. Por tanto, observando varios valores significativos en la autocorrelación simple y siendo la primera autocorrelación parcial estacional (12) la de mayor valor, se propone un $SAR(1)$.




Figura 3.4: *Función de Autocorrelación Simple de los residuos ARMA(1,0)*




Figura 3.5: *Función de Autocorrelación Parcial de los residuos ARMA(1,0)*

Proponemos entonces un $SARIMA(1,0,0)x(1,0,0)/[12]$. Este modelo presenta todos los coeficientes significativos, así como estimaciones de los parámetros autorregresivos lejanas a 1 (ver cuadro 3.4).

Variable	Estimate	Std. Error	Pr(> z)		ar1	sar1	intercepto
ar1	0.6886	0.0681	<2.2e-16 ***	ar1	1.0000	0.0090	0.0201
sar1	0.6122	0.0742	<2.2e-16 ***	sar1	0.0090	1.0000	0.1358
intercepto	10.3848	0.0750	<2.2e-16 ***	intercepto	0.0201	0.1358	1.0000

Cuadro 3.4: *Coefficientes del modelo SARIMA(1,0,0) × (1,0,0)/[12]*

Cuadro 3.5: *Matriz de correlaciones del modelo SARIMA(1,0,0) × (1,0,0)/[12]*

Obtendríamos entonces el modelo $(1 - 0,688685B) \cdot (1 - 0,612259B^{12})X_t = 10,384891 + \varepsilon_t$. En primer lugar, no aparece correlación entre los parámetros (véase el cuadro 3.5), por lo que vamos a estudiar el comportamiento de sus residuos. Para este estudio volvemos a evaluar de nuevo los gráficos de la *FAS* y *FAP*. Observamos ahora que solo la sexta autocorrelación es significativa, por lo que, no encontrando sentido a reflejar relaciones entre datos a distancia 6, decidimos establecer este modelo como primera opción (ver figuras 3.6 y 3.7).




Figura 3.6: *FAS de los residuos SARIMA(1,0,0)x(1,0,0)[12]*




Figura 3.7: *FAP de los residuos SARIMA(1,0,0)x(1,0,0)[12]*

No habiendo ninguna autocorrelación significativa de orden justificable, estamos en disposición de introducir las variables explicativas para realizar un ajuste más preciso. Proponemos el modelo $SARIMA(1,0,0)x(1,0,0)[12]$ con variables explicativas. En este caso, tras hacerlo, observamos que la variable *bisiesto* no es significativa ($p - valor \approx 0,2895$) y tampoco presenta un signo coherente con el negocio ($-0,03951$) pues un año bisiesto cuenta con un día adicional por lo que la compraventa debería ser mayor. Es por esto por lo que eliminamos la variable explicativa *bisiesto*. Reproduciendo el modelo $SARIMA(1,0,0)x(1,0,0)_{12}$ con las otras dos variables exógenas, vemos que como todos los parámetros autorregresivos son significativos y no cercanos a 1 y los asociados a las variables explicativas son también significativos y de signo coherente con el negocio (ver cuadro 3.6).

Variable	Estimate	Std. Error	Pr(> z)
ar1	0.8238045	0.0518728	<2.2e-16 ***
sar1	0.6735011	0.0667846	<2.2e-16 ***
intercepto	10.4467132	0.1115494	<2.2e-16 ***
semanaSanta	-0.0299858	0.0045630	4.982e-11 ***
laborables	0.0114240	0.0017078	2.241e-11 ***

Cuadro 3.6: *Coeficientes del modelo SARIMA(1,0,0)×(1,0,0)[12] con variables explicativas sin bisiesto*

Con los resultados obtenidos en el cuadro 3.6 obtenemos el modelo multivariante *SARIMA* con variables explicativas dado por la fórmula:

$$X(t) = \frac{1}{(1 - 0,82B)(1 - 0,76B^{12})} \cdot e(t) + 10,44 - 0,0299858 \cdot sS(t) + 0,011424 \cdot laborables(t)$$

(denotaremos por “sS(t)” a la variable “semanaSanta(t)” para una mayor legibilidad)

Además, estos parámetros no presentan correlación entre sí (véase cuadro A.1 presente en el anexo). Sin embargo, este modelo no supera la prueba de incorrelación residual a un nivel de significatividad de $\alpha = 0,05$, pues obtenemos *p-valores* inferiores a 0,05 (ver cuadro 3.7).

Retard	6	12	18	24	30	36	42	48
p-value	0,06070415	0,04281146	0,07087674	0,02890001	0,03472970	0,04982588	0,11276617	0,21933390

Cuadro 3.7: *Resultados del test de Ljung-Box*

Con el modelo establecido bajo las hipótesis de significatividad requeridas y con el valor adicional de las variables explicativas, vamos a estudiar posibles influencias de datos *outliers* que no haya podido captar y que puedan tener un impacto considerable en el modelo. Para ello seguiremos unos pasos concretos: primero detectamos todos los posibles *outliers* aditivos y de cambio de nivel para el modelo propuesto, seguidamente introducimos tan solo el de mayor impacto sobre el modelo y por último, evaluaremos nuevamente. La adición de valores *outliers* es realizada secuencialmente uno a uno, debido a que la influencia de algunos datos atípicos pueden repercutir sobre el resto. Para nuestro modelo detectamos varios valores destacables. Tras dos iteraciones de este proceso conseguimos eliminar todos los *outliers* incluyendo en el modelo la influencia del dato correspondiente a marzo de 2014 y marzo de 2011 como datos atípicos de cambio de nivel. De esta forma obtenemos entonces el modelo

SARIMA(1,0,0)x(1,0,0)[12] con variables explicativas de calendario sin *bisiesto* y con *outliers*. Este modelo conserva las propiedades vistas anteriormente: significatividad de los parámetros autorregresivos, del intercepto y de las asociadas a las variables explicativas; además, los coeficientes autorregresivos no violan la condición de estacionariedad (ver cuadro 3.8).

Variable	Estimate	Pr(> z)	Variable	Estimate	Pr(> z)
ar1	0.7934386	<2.2e-16 ***	LS63	0.2452266	2.028e-05 ***
sar1	0.7443432	<2.2e-16 ***	LS27	-0.2322300	2.457e-05 ***
intercepto	10.4979037	<2.2e-16 ***	laborables	0.0121127	4.151e-16 ***
semanaSanta	-0.0274804	3.271e-12 ***			

Cuadro 3.8: Coeficientes del SARIMA(1,0,0)×(1,0,0)[12] con outliers y variables explicativas

Con los resultados obtenidos en el cuadro 3.8 obtenemos el modelo multivariante:

$$X(t) = \frac{1}{(1 - 0,79B)(1 - 0,74B^{12})} \cdot e(t) + 10,49 - 0,02 \cdot sS(t) + 0,01 \cdot laborables(t) + 0,24 \cdot LS63(t) - 0,23 \cdot LS27(t)$$

	ar1	sar1	intercept	semanaSanta	laborables	LS63	LS27
ar1	1.0000	0.1933	-0.0939	0.0545	0.0480	0.3467	0.2094
sar1	0.1933	1.0000	0.0230	0.1740	0.0892	0.1246	0.0847
intercept	-0.0939	0.0230	1.0000	-0.0309	0.0302	-0.2288	-0.3265
semanaSanta	0.0545	0.1740	-0.0309	1.0000	0.0363	0.1198	0.0135
laborables	0.0480	0.0892	0.0302	0.0363	1.0000	0.0667	-0.0314
LS63	0.3467	0.1246	-0.2288	0.1198	0.0667	1.0000	0.0297
LS27	0.2094	0.0847	-0.3265	0.0135	-0.0314	0.0297	1.0000

Cuadro 3.9: Matriz de correlaciones del modelo SARIMA(1,0,0)×(1,0,0)[12] con variables explicativas e intervenciones

Como se puede ver en el cuadro 3.9, este modelo tampoco presenta correlación alta entre los parámetros.

Vamos a estudiar ahora la validez de este modelo desde el punto de vista de sus residuos. En primer lugar, el modelo cumple que para todos los retardos, el *p-valor* obtenido es mayor de 0,05 por lo que no tenemos evidencias suficientes para rechazar la hipótesis nula y por

tanto el modelo presenta incorrelación entre los residuos (ver cuadro 3.10). Por otro lado, para las pruebas de homocedasticidad y normalidad tampoco tenemos evidencias suficientes para rechazar la hipótesis nula (ver cuadro 3.11). Se cumplen así todas las hipótesis necesarias.

Retard	6	12	18	24	30	36	42	48
p-value	0,2987598	0,2970673	0,3531712	0,5084220	0,5095581	0,6281330	0,7782286	0,8608943

Cuadro 3.10: *Prueba de Ljung-Box*

Prueba	p-value	Prueba	p-value
Breusch-Pagan	0,547	Lilliefors	0,619

Cuadro 3.11: *Resultados de las pruebas de homocedasticidad y normalidad*

Antes de avanzar con las predicciones que proporciona este modelo, se calcularán otros a través de los procesos automáticos de los que disponemos. En primer lugar, calcularemos el mejor modelo con la función *auto.arima* y posteriormente con nuestra función de búsqueda. Añadimos también el modelo de líneas áreas al tratarse de un referente dentro del ámbito de los modelos estacionales. Este modelo cumple las hipótesis necesarias, como se puede consultar en los cuadros A.2 y A.3 presentes en el anexo. Para todos estos modelos añadiremos las variables explicativas y *outliers* detectados en los pasos previos. Observamos la tabla resumen con todos los modelos a disposición (ver tabla 3.12). Nótese que el mejor modelo encontrado por la función de búsqueda por *MAPE* y *auto.arima* coinciden.

Método de cálculo	Modelo resultante	Error MAPE <i>train</i>
Ajuste manual	SARIMA(1,0,0)x(1,0,0)[12]	5.548 %
Auto.arima	SARIMA(0,1,0)(0,1,1)[12]	4.830 %
Función de búsqueda por AIC	SARIMA(2,0,1)(0,0,2)[12]	5.346 %
Función de búsqueda por MAPE	ARIMA(0,1,0)(0,1,1)[12]	4.830 %
Líneas aéreas	SARIMA(0,1,1)x(0,1,1)[12]	4.843 %

Cuadro 3.12: *Modelos y error de diferentes métodos de cálculo para la serie nacional*

Cálculo de predicciones

Con todos los modelos a nuestra disposición vamos a estudiar las predicciones sobre el conjunto de test y su comportamiento. Para calcular los valores futuros seguiremos una serie

de pasos para tratar de conseguir la mayor precisión posible. En primer lugar, se realizará una predicción a horizonte uno, esto es, calcularemos el valor inmediatamente posterior a los datos de entrenamiento. Con la estimación realizada calcularemos el error *MAPE* de este punto. Después, añadiremos un nuevo valor real del conjunto de prueba a nuestro modelo y repetiremos el algoritmo hasta completar todos los instantes temporales que comprenden el conjunto de *test*. Siguiendo esta metodología para las predicciones obtenemos los siguientes errores *MAPE* sobre el conjunto de *test*.

Método de cálculo	Modelo resultante	Error MAPE test
Ajuste manual	SARIMA(1,0,0)x(1,0,0)[12]	7.677 %
Auto.arima	SARIMA(0,1,0)(0,1,1)[12]	8.794 %
Función de búsqueda por AIC	SARIMA(2,0,1)(0,0,2)[12]	7.956 %
Función de búsqueda por MAPE	ARIMA(0,1,0)(0,1,1)[12]	8.794 %
Líneas aéreas	SARIMA(0,1,1)x(0,1,1)[12]	7.864 %

Cuadro 3.13: Modelos y error de test de diferentes métodos de cálculo para la serie nacional

Con los resultados obtenidos en los cuadros 3.12 y 3.13 podemos determinar que el mejor modelo es el conseguido a partir del ajuste manual. A pesar de ser el que mayor error presenta sobre el conjunto de entrenamiento (ver cuadro 3.12), es el menos sobreajustado (menor diferencia entre error de *train* y *test*) y mejor error de test (ver cuadro 3.13). El modelo de líneas aéreas nos sirve como una buena referencia ya que presenta resultados similares. Podemos observar las diferencias gráficas así como el intervalo de confianza para cada modelo en las figuras 3.8, 3.9, 3.10 y 3.11. Para mayor detalle véanse las figuras en el apartado A.4 del anexo.




Figura 3.8: Predicciones modelo SARIMA(0,1,0)(0,1,1)[12]




Figura 3.9: Predicciones modelo SARIMA(2,0,1)(0,0,2)[12]




Figura 3.10: *Predicciones modelo SARIMA(1,0,0)(1,0,0)[12]*




Figura 3.11: *Predicciones modelo SARIMA(0,1,1)(0,1,1)[12]*

3.4. Análisis datos autonómicos y provinciales

Una vez determinado el modelo de referencia para la serie nacional, vamos a estudiar el comportamiento de las series autonómicas y provinciales. Para estas aplicaremos la función *auto.arima*, del paquete *forecast* de *RStudio*, y la función de búsqueda implementada que busca el mejor *AIC* y *MAPE*. Véanse los cuadros A.4 y A.5 presentes en el apartado A.5 del anexo, donde se presenta, para cada comunidad y provincia, el modelo calculado con las metodologías ya mencionadas. Cabe destacar que para cada modelo se seleccionan las variables explicativas necesarias siguiendo el criterio establecido en el ajuste manual. Para más detalle sobre el método de cálculo véase el apartado B del anexo. Para determinar cual de los tres acercamientos es el que mejor resultados nos ofrece, promediamos los errores por comunidad y provincia. De los modelos escogidos en *train* (ver cuadros 3.14 y 3.15) el que mejor *MAPE* en *test* medio presenta es, como era de esperar, el que utiliza la función de búsqueda basada en el *MAPE*. Dado que es una métrica porcentual, pequeñas variaciones en los valores reales pueden generar errores relativos muy elevados, especialmente cuando los datos son de magnitud reducida. Es por esto que, comunidades o provincias con valores pequeños suponen un aumento significativo del error. Sin embargo, veremos a continuación cómo las diferentes estrategias de predicción consiguen una mejora sobre este indicador.

Comunidad	Error train AIC	Error train MAPE	Error train Auto.arima
Andalucía	7.120209 %	6.479951 %	7.115133 %
Aragón	11.275816 %	10.200668 %	10.590624 %
Principado de Asturias	11.381952 %	10.600069 %	10.942884 %
Islas Baleares	10.401743 %	10.047630 %	9.931626 %
Canarias	10.138341 %	9.769168 %	11.104081 %
Cantabria	13.093774 %	13.093774 %	12.318486 %
Castilla y León	8.429392 %	7.408210 %	8.991255 %
Castilla - La Mancha	9.487041 %	9.296117 %	10.025139 %
Cataluña	6.828305 %	6.828305 %	6.706142 %
Comunidad Valenciana	7.036343 %	6.429521 %	6.661040 %
Extremadura	12.799119 %	11.111523 %	14.082028 %
Galicia	10.488115 %	10.247880 %	9.753633 %
Madrid	9.682843 %	8.756098 %	9.513919 %
Murcia	11.347032 %	9.444010 %	11.349504 %
Navarra	13.597370 %	11.439322 %	12.939121 %
País Vasco	8.832798 %	8.832798 %	10.185651 %
Rioja	20.652782 %	16.583838 %	20.839293 %
Ceuta	34.580034 %	33.139222 %	44.059010 %
Melilla	28.129020 %	25.800266 %	27.589939 %
Media	12.3251 %	11.3706 %	12.9623 %

Cuadro 3.14: Errores de los modelos por comunidad autónoma y criterio en train

Provincia	Error train AIC	Error train MAPE	Error train Auto.arima
Almería	19.851975 %	18.205380 %	17.083817 %
Cádiz	9.167316 %	9.167316 %	10.638914 %
Córdoba	12.950881 %	11.277595 %	11.139774 %
Granada	11.917413 %	11.069068 %	12.410460 %
Huelva	13.409987 %	10.499504 %	13.067779 %
Jaén	12.980288 %	11.979634 %	12.873993 %
Málaga	9.973778 %	9.199393 %	8.767554 %
Sevilla	11.482615 %	9.269896 %	10.635574 %
Huesca	17.839878 %	15.159803 %	17.663990 %
Teruel	22.656491 %	16.347534 %	22.536711 %
Zaragoza	13.870181 %	12.595081 %	13.397376 %

Provincia	Error train AIC	Error train MAPE	Error train Auto.arima
Asturias	11.381952 %	10.600069 %	10.942884 %
Islas Baleares	10.401743 %	10.047630 %	9.931626 %
Las Palmas	12.790478 %	12.790478 %	12.726305 %
Santa Cruz de Tenerife	10.927290 %	9.857445 %	11.073243 %
Cantabria	13.093774 %	13.093774 %	12.318486 %
Ávila	18.130835 %	18.130835 %	19.089567 %
Burgos	14.744916 %	14.041973 %	13.953136 %
León	14.505745 %	14.610920 %	15.318381 %
Palencia	17.776434 %	15.404330 %	17.408424 %
Salamanca	19.927617 %	19.927617 %	15.215140 %
Segovia	21.604882 %	18.530657 %	21.229620 %
Soria	27.240005 %	24.623391 %	26.869641 %
Valladolid	16.750578 %	16.417110 %	17.786324 %
Zamora	18.638896 %	17.465991 %	19.988725 %
Albacete	18.747648 %	18.993079 %	19.055240 %
Ciudad Real	14.828813 %	13.196943 %	16.252234 %
Cuenca	27.222900 %	23.005147 %	26.961350 %
Guadalajara	17.508842 %	16.501696 %	20.651770 %
Toledo	14.592205 %	14.408982 %	14.089523 %
Barcelona	7.762258 %	7.762258 %	7.162218 %
Girona	9.110081 %	9.172145 %	11.583781 %
Lleida	12.653544 %	12.715830 %	13.243691 %
Tarragona	12.205078 %	10.528457 %	11.411803 %
Alicante	6.515342 %	5.867235 %	6.919152 %
Castellón	16.561866 %	15.467810 %	15.508539 %
Valencia	8.494060 %	7.856679 %	8.216711 %
Badajoz	13.977826 %	11.944156 %	14.712355 %
Cáceres	14.922023 %	14.733047 %	16.199867 %
A Coruña	14.084652 %	12.606541 %	12.517940 %
Lugo	20.620712 %	18.928714 %	20.370742 %
Ourense	15.087442 %	13.150942 %	16.529504 %
Pontevedra	9.657423 %	9.118376 %	9.552214 %
Madrid	9.682843 %	8.756098 %	9.513919 %
Murcia	11.347032 %	9.444010 %	11.349504 %
Navarra	13.597370 %	11.439322 %	12.939121 %
Álava	20.899886 %	20.899886 %	26.876998 %
Vizcaya	10.835005 %	10.835005 %	12.971911 %

Provincia	Error train AIC	Error train MAPE	Error train Auto.arima
Guipúzcoa	13.573172 %	13.310261 %	13.761247 %
La Rioja	20.652782 %	16.583838 %	20.839293 %
Ceuta	34.580034 %	33.139222 %	44.059010 %
Melilla	28.129020 %	25.800266 %	27.589939 %
Media	15.42050 %	14.16305 %	15.67129 %

Cuadro 3.15: Errores de los modelos por provincia y criterio en train

Por tanto, con el modelo que usa la función de búsqueda basado en el *MAPE* realizamos las predicciones para cada comunidad y provincia. Obtenemos de esta forma los siguientes resultados de error sobre las predicciones.

	Error MAPE medio de test
Comunidad	15,79419 %
Provincia	15,34842 %

Cuadro 3.16: Error *MAPE* medio de test por nivel territorial

3.5. Estrategia *Bottom-up*

Como se ha podido ver en el apartado 2.3.2, la estrategia *Bottom-up* plantea la estimación de un nivel superior en la jerarquía del sistema a partir de los niveles inferiores. En la mayoría de ocasiones se plantea la cuestión sobre si un mayor nivel de detalle de los datos, segmentados por grupos, aporta una mayor precisión a las estimaciones. En nuestro caso contamos con el nivel provincial, seguido del autonómico, que emplearemos para determinar el nacional. Con el objetivo de decidir cual de los tres acercamientos al valor real resulta más acertado, estudiaremos en primer lugar aplicar la estrategia desde el nivel provincial y posteriormente se llevará acabo desde el nivel autonómico. De esta forma evaluaremos, para este caso concreto, qué nivel de la jerarquía nos proporciona mejores resultados de error frente al nivel superior, el nacional. Así pues, sumando las predicciones realizadas para cada provincia y comunidad obtendremos una estimación para la serie nacional. Con las estimaciones para cada estrategia se calcula el error *MAPE* (ver el cuadro 3.17) donde las estimaciones mediante el estudio de las comunidades y las provincias logran mejorar el error obtenido de 7,677 % en el ajuste manual. Tanto para el nivel autonómico, como el provincial,

el modelo según el criterio *MAPE* resulta ser el que menor error tiene (ver cuadros 3.14 y 3.15).

Estrategia	Error MAPE test comunidades	Error MAPE test provincias
Suma por modelo AIC	6.437 %	6.992 %
Suma por modelo MAPE	6.148 %	6.317 %
Suma por modelo Autoarima	6.490 %	6.740 %

Cuadro 3.17: *Comparación resultados de test*

Como podemos observar en las figuras 3.12 y 3.13 estos modelos tienen un comportamiento más preciso que el ajuste manual (ver figuras 3.8, 3.9, 3.10 y 3.11). Para ver con más detalle las predicciones de todos los modelos véanse las figuras del apartado A.6 presente en el anexo.




Figura 3.12: *Estimación Bottom-up con modelos MAPE por comunidad*




Figura 3.13: *Estimación Bottom-up con modelos MAPE por provincia*

Podemos ver como ambas aproximaciones al valor real son bastante acertadas y suponen una mejora significativa de lo conseguido a partir del ajuste manual a la serie nacional. Estaríamos consiguiendo más de 1,5 puntos porcentuales de mejora del error de nuestras predicciones. En este caso el mayor detalle de las observaciones provinciales no supone una mejora, por lo que la complejidad es mayor y por tanto el resultado se ve afectado negativamente.

3.6. Estrategia *Top-down*

Otra de las cuestiones prácticas es la necesidad de conocer el valor de los niveles inferiores de la jerarquía. Para ello se emplea la estrategia *Top-down*, esto es, a partir de las observaciones

del nivel más alto de la jerarquía se predice el valor para los niveles inferiores. Para realizar este proceso primero se calcula la estimación del nivel más alto y se reparte proporcionalmente al resto de categorías de los niveles inferiores. El porcentaje de cada grupo se calcula con datos históricos o conocimiento previo del contexto a estudiar. En nuestro caso calcularemos esta proporción en función de las estimaciones para cada comunidad o provincia. Esto es, para cada valor predicho calcularemos el porcentaje que representa respecto del total estimado para todas las comunidades o provincias. Obsérvese por tanto que, aunque la predicción de la serie nacional es la que gobierna, es preciso disponer de las predicciones realizadas en los niveles más bajos para llevar a cabo la desagregación. Con la predicción dada por la serie nacional y este peso de cada comunidad, y posteriormente provincia, podremos determinar una estimación para cada una de ellas. De los tres modelos disponibles con los que contamos, tomamos como referencia el calculado por el criterio *MAPE* al ser el que menor error sobre el modelo presenta.

Para la cuestión autonómica observamos en el cuadro A.6 un error *MAPE* sobre las predicciones elevado en aquellas comunidades con un menor valor de compraventa de viviendas. Recordamos que al tratarse de una métrica porcentual, variaciones en pequeñas magnitudes suponen efectos grandes en el resultado.

De esta forma tendríamos la estimación para cada comunidad partiendo de los datos nacionales. En media, con esta estrategia y para este caso concreto, obtendríamos un error sobre test de 16,534 % (véase el cuadro 3.18). Este es mayor que el obtenido con las predicciones realizadas directamente sobre cada serie autonómica o provincial (véase cuadro 3.16). El nivel de detalle que obviamos al no tener en cuenta la variabilidad de cada serie repercute de forma significativa en el resultado final.

De forma análoga repetimos este proceso para calcular las estimaciones de cada provincia (véase el cuadro A.7 presente en el anexo). Para este caso, tenemos que el error medio de todas las provincias es de 15,910 % (véase nuevamente el cuadro 3.18). A pesar de obtener una ligera mejora respecto al obtenido por comunidades este error sigue siendo superior a lo esperado.

Método	Error MAPE Medio en test
Top-down comunidades	16,534 %
Top-down provincias	15,910 %

Cuadro 3.18: *Error MAPE medio en test por método*

3.7. Estrategia *Middle-out*

La última estrategia propuesta, *Middle-out*, consiste en tomar como referencia una capa intermedia del sistema jerárquico. En las metodologías previas se parte de los niveles superior e inferior con el objetivo de predecir el resto de series de la estructura. Para este caso, el objetivo principal queda a criterio de la persona que realiza el estudio, pues esta estrategia consiste en aunar las dos ya propuestas para conseguir predicciones de un nivel superior o de un nivel inferior. Aplicaríamos entonces una metodología *Bottom-up* para predecir valores en el nivel superior y una *Top-down* para los del inferior. Cabe destacar que en este último caso, la serie de referencia es la intermedia donde dentro de cada comunidad autónoma, se usan las predicciones de sus provincias para distribuir proporcionalmente la predicción de cada una de ellas.

Para nuestro caso particular, la estrategia *Middle-out* supone una comprobación de los resultados obtenidos. Partiendo de las series calculadas para cada comunidad, nivel intermedio, estaríamos en disposición entonces de realizar una predicción nacional empleando el apartado 2.3.2. Para realizar unas predicciones sobre las provincias replicaríamos el apartado 3.6 teniendo en cuenta el cálculo de los porcentajes y las relaciones entre comunidades y provincias. Partiendo de los resultados obtenidos en la estrategia *Bottom-up* y replicando la *Top-down*, tomando como referencia las comunidades, presentamos los siguientes resultados para esta metodología (ver cuadro 3.19).

Metodología	Error MAPE en test
Bottom-up	6.148 %
Top-down	16.014 %

Cuadro 3.19: *Resultados Middle-out en test desde el nivel autonómico*

3.8. Discusión

El primer objeto de comparación es la influencia de las diferentes estrategias dentro del marco de la estimación masiva de series temporales. El ejemplo de compraventa de viviendas nos ha facilitado experimentar con un caso real y con el impacto de datos con mayor cantidad de niveles jerárquicos. En esta comparación se ha puesto de relieve el trabajo minucioso de ajustar un modelo de forma manual; con inclusión de variables explicativas y verificación de hipótesis entre otros pasos para obtener el resultado. Por el contrario, el proceso automático,

que sustituye a la intervención humana, tiene asociado un coste de eficiencia computacional. Hemos comprobado que la metodología *Bottom-up* ofrece mejores resultados que un ajuste manual al predecir la serie del nivel superior, dentro del sistema jerárquico. El nivel de detalle que somos capaces de explicar en una capa intermedia, por comunidades, parece beneficiar el error cometido en las predicciones. Alcanzamos una mejora de más de 1,5 puntos porcentuales del error *MAPE* sobre las estimaciones (véase cuadro 3.20).

Método	Error MAPE Medio en test
Ajuste manual	7.677 %
Bottom-up comunidades	6.148 %
Bottom-up provincias	6.317 %

Cuadro 3.20: Comparación del error *MAPE* medio en test por método

Por otro lado, las estrategias que pretenden descender en la escala jerárquica parecen no presentar muy buenos resultados. La variabilidad existente en los niveles inferiores de la jerarquía no se muestra en la serie principal (ver cuadro 3.18). El cálculo de las proporciones asociadas a cada categoría es un aditivo al error acumulado de la predicción. No obstante, este tipo de planteamientos se realizan en situaciones donde se necesita conocer estimaciones sobre niveles inferiores. En este contexto el error dispuesto a asumir crece, proporcionando entonces un acercamiento razonable a la solución del problema.

Adicionalmente, se ha comparado la eficacia de la función de búsqueda del mejor modelo y los algoritmos ya incluidos en *R*. En el caso de la serie nacional, con un ajuste manual, ha supuesto un mejor modelo. El nivel de detalle en detección de *outliers* y elección de parámetros nos han proporcionado una ventaja sobre el algoritmo automático. Sin embargo, para la cuestión de estimación masiva, donde no se pueden determinar todos los modelos con la misma exactitud, el modelo que sigue el criterio de comparación *AIC* ha supuesto una mejora respecto a la función *auto.arima*. Adicionalmente, el criterio *MAPE* ha sido el que mejores resultado nos ofrece. La desventaja ha sido la disminución de la velocidad computacional. Para la estimación *Bottom-up* podemos ver en el cuadro 3.17 una mejora del modelo ajustado mediante la función *auto.arima* y el mejor modelo según el criterio *MAPE* de apenas 0,3 puntos porcentuales, tanto en el modelo para las comunidades como para las provincias. Sin embargo, la eficiencia de la función *auto.arima* es superior. Dependiendo de las necesidades del problema, en ocasiones pequeñas mejoras sobre la precisión resultan cruciales y en otros casos la gestión y optimización de los recursos es el principal factor.

Capítulo 4

Conclusiones

La estimación de series temporales requiere decisiones que no siempre son objetivas, influidas por el contexto, los datos y los recursos disponibles. En este análisis se han expuesto las diferencias de resultados que surgen según la estrategia empleada.

En primer lugar, se ha evaluado el impacto de distintas técnicas jerárquicas de predicción. En estas estructuras, la estrategia *Bottom-up*, desde el nivel autonómico, mejora significativamente la estimación nacional respecto al enfoque manual gracias al mayor nivel de detalle. Por otro lado, la estrategia *Top-down* resulta adecuada cuando se busca mayor detalle en niveles inferiores, aunque conlleva mayor error debido a la mayor variabilidad. La estrategia *Middle-out* reúne las ventajas de cada metodología, mayor precisión para la estimación nacional y explica la variabilidad de niveles inferiores.

En segundo lugar, se ha contrastado el rendimiento de modelos generados con la función de búsqueda personalizada frente a la función *auto.arima* de *R*, ambas guiadas por el criterio *AIC*. Los resultados evidencian una mejora al considerar la validez de hipótesis y la significatividad de los modelos. Además, la selección basada en el error *MAPE* permite minimizar los errores en la tabla de test, tal y como cabía esperar. Esto es especialmente útil en contextos de predicción masiva, como se observa en los errores a nivel nacional, autonómico y provincial.

En conclusión, la combinación de algoritmos generalizados junto a una estrategia de predicción masiva como *Bottom-up* y el criterio de selección *MAPE* es la que mejores resultados obtiene para predecir valores futuros. Si se busca optimizar la gestión de recursos, los algoritmos ya incluidos suponen una ventaja en eficiencia computacional manteniendo el criterio de selección y la estrategia de predicción. Si por el contrario, se busca la mayor precisión posible, el cumplimiento de las hipótesis de ruido blanco y la significatividad de los parámetros logran mejores predicciones.

Bibliografía

- [1] Ceyda Akbulut. Introduction to hierarchical time series. *Geek Culture*, 2021.
- [2] G. E. P. Box and D. R. Cox. An analysis of transformations. *Journal of the Royal Statistical Society. Series B, Statistical Methodology*, 26(2):211–252, 1964.
- [3] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, and Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. Wiley, 5 edition, 2016.
- [4] Ana Luíza Xavier Cunha, Karina Paula Barbosa de Andrade Lima, and Romildo Morant de Holanda. Rainfall forecast for the municipality of vitória de santo antão – pe. *Revista de Gestão Social e Ambiental*, 17(10):e03972, 2023. CC BY 4.0 License.
- [5] D. A. Dickey and W. A. Fuller. Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366):427–431, 1979.
- [6] Rob J Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice (2nd ed)*. OTexts, 2018.
- [7] INE - Instituto Nacional de Estadística. Compraventa de viviendas según régimen y estado (6150), s. f. INE. Consultado enero de 2025.
- [8] S. Makridakis, S. C. Wheelwright, and R. J. Hyndman. The accuracy of extrapolation (time series) methods: Results of a forecasting competition. *Journal of Forecasting*, 1(2):111–153, 1982.
- [9] Spyros Makridakis, Evangelos Spiliotis, and Vassilis Assimakopoulos. M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, January 2022.
- [10] G. T. Walker and G. U. Yule. Periodicity in series of related terms. *Proceedings of the Royal Society of London*, 1931.

Apéndice A

Anexo

A.1. Momentos de los procesos básicos

A.1.1. Proceso de medias móviles

Demostración de la estacionariedad de un proceso $MA(q)$.

Sea el proceso de medias móviles de orden q con media $\mu = 0$:

$$X_t = \theta(B)\varepsilon_t = \varepsilon_t - \theta_1\varepsilon_{t-1} - \dots - \theta_q\varepsilon_{t-q}$$

Siendo ε_t un proceso de ruido blanco. Calcularemos todos sus momentos para estudiar su estacionariedad.

-Media:

$$E[X_t] = E[\varepsilon_t - \theta_1\varepsilon_{t-1} - \dots - \theta_q\varepsilon_{t-q}] = E[\varepsilon_t] - \theta_1E[\varepsilon_{t-1}] - \dots - \theta_qE[\varepsilon_{t-q}]$$

Como ε_t sigue un proceso de ruido blanco, esto es, $E[\varepsilon_t] = 0$.

$$\Rightarrow E[X_t] = 0 - \theta_1 0 - \dots - \theta_q 0 = 0$$

- Varianza: Haciendo uso de las propiedades de la varianza y puesto que $Cov(\varepsilon_t, \varepsilon_{t-h}) = 0$ obtenemos que:

$$\begin{aligned} Var(X_t) &= Var(\varepsilon_t - \theta_1\varepsilon_{t-1} - \dots - \theta_q\varepsilon_{t-q}) = Var(\varepsilon_t) + \theta_1^2 Var(\varepsilon_{t-1}) + \dots + \theta_q^2 Var(\varepsilon_{t-q}) = \\ &= \sigma^2 + \theta_1^2 \sigma^2 + \dots + \theta_q^2 \sigma^2 = (1 + \theta_1^2 + \dots + \theta_q^2) \sigma^2 \end{aligned}$$

El proceso $MA(q)$ es siempre estacionario al no depender del instante temporal t .

A.1.2. Proceso autorregresivo

Momentos de un proceso $AR(p)$ con media $\mu = 0$:

$$\begin{aligned}\mathbb{E}[X_t] &= 0 \\ \text{Var}(X_t) &= \phi_1\gamma_1 + \cdots + \phi_p\gamma_p + \sigma^2 \\ C_X(t, t-h) &= \phi_1\gamma_{h-1} + \cdots + \phi_p\gamma_{h-p} \\ \rho_X(t, t-h) &= \phi_1\rho_{h-1} + \cdots + \phi_p\rho_{h-p}\end{aligned}$$

A.2. Esquema jerárquico de la base de datos




Figura A.1: Esquema jerárquico de la base de datos de compraventa de viviendas

A.3. Ajuste manual

A.3.1. Matriz de correlaciones modelo SARIMA(1,0,0) × (1,0,0)[12] con variables explicativas sin bisiesto

	ar1	sar1	intercept	semanaSanta	laborables
ar1	1,0000	0,0547	0,0585	−0,0015	0,0290
sar1	0,0547	1,0000	0,1054	0,1572	0,0722
intercept	0,0585	0,1054	1,0000	0,0018	0,0451
semanaSanta	−0,0015	0,1572	0,0018	1,0000	0,0172
laborables	0,0290	0,0722	0,0451	0,0172	1,0000

Cuadro A.1: Matriz de correlaciones del modelo SARIMA(1,0,0) × (1,0,0)[12] con variables explicativas sin bisiesto

A.3.2. Líneas aéreas

Hipótesis del modelo líneas aéreas, SARIMA(0,1,1)x(0,1,1)[12]

Retard	p-value
6	0.1423913
12	0.2912036
18	0.3809288
24	0.2514220
30	0.2078807
36	0.2164644
42	0.3167708
48	0.2948040

Cuadro A.2: Resultados de la prueba de Ljung-Box

Prueba	p-value
Breusch-Pagan	0.464
Lilliefors	0.217

Cuadro A.3: Resultados de las pruebas de homocedasticidad y normalidad

A.4. Cálculo de predicciones




Figura A.2: *Predicciones modelo SARIMA(0,1,0)(0,1,1)[12]*




Figura A.3: *Predicciones modelo SARIMA(2,0,1)(0,0,2)[12]*




Figura A.4: *Predicciones modelo SARIMA(1,0,0)(1,0,0)[12]*




Figura A.5: *Predicciones modelo SARIMA(0,1,1)(0,1,1)[12]*

A.5. Tabla modelos autonómicos y provinciales

A.5.1. Tabla modelo por comunidad

Comunidad	Modelo _Autoarima	Modelo _MAPE	Modelo _AIC
Andalucía	ARIMA(0,1,2)(1,0,2)[12]	ARIMA(2,1,1)(2,1,0)[12]	ARIMA(0,1,2)(1,0,2)[12]
Aragón	ARIMA(0,1,1)(1,0,1)[12]	ARIMA(1,1,0)(0,1,1)[12]	ARIMA(1,0,1)(1,0,0)[12]
Asturias	ARIMA(0,1,3)(0,0,2)[12]	ARIMA(0,1,2)(0,1,1)[12]	ARIMA(1,0,0)(0,0,2)[12]
Islas Baleares	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(1,0,1)(0,0,2)[12]	ARIMA(2,0,0)(0,0,2)[12]
Canarias	ARIMA(0,1,1)(0,0,2)[12]	ARIMA(0,1,1)(1,0,2)[12]	ARIMA(0,1,1)(2,0,0)[12]
Cantabria	ARIMA(0,1,1)	ARIMA(1,0,1)(1,1,0)[12]	ARIMA(1,0,1)(1,1,0)[12]
Castilla y León	ARIMA(1,1,1)(2,0,0)[12]	ARIMA(1,1,1)(0,1,1)[12]	ARIMA(1,1,1)(1,0,1)[12]
Castilla - La Mancha	ARIMA(3,1,0)(1,0,0)[12]	ARIMA(0,1,0)(0,1,2)[12]	ARIMA(0,1,2)(2,0,1)[12]
Cataluña	ARIMA(0,1,2)(0,1,1)[12]	ARIMA(2,1,0)(0,1,1)[12]	ARIMA(2,1,0)(0,1,1)[12]
Comunidad Valenciana	ARIMA(3,1,1)(2,0,0)[12]	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)(2,0,0)[12]
Extremadura	ARIMA(0,1,2)	ARIMA(2,1,0)(0,1,1)[12]	ARIMA(1,1,1)(2,0,0)[12]
Galicia	ARIMA(1,1,1)(2,0,0)[12]	ARIMA(1,1,0)(1,1,0)[12]	ARIMA(0,1,0)(0,0,2)[12]
Madrid	ARIMA(0,1,2)(1,0,2)[12]	ARIMA(1,1,2)(2,1,1)[12]	ARIMA(0,1,2)(2,0,0)[12]
Murcia	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(1,1,2)(2,1,1)[12]	ARIMA(0,1,1)(2,0,0)[12]
Navarra	ARIMA(0,1,3)(2,0,0)[12]	ARIMA(0,0,2)(1,1,1)[12]	ARIMA(0,0,2)(1,0,0)[12]
País Vasco	ARIMA(0,1,2)(2,0,0)[12]	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)(0,1,1)[12]
La Rioja	ARIMA(1,1,1)(1,0,0)[12]	ARIMA(2,0,2)(0,1,1)[12]	ARIMA(0,1,1)
Ceuta	ARIMA(1,0,0)(2,0,0)[12]	ARIMA(2,1,0)(0,1,1)[12]	ARIMA(1,0,0)(0,1,1)[12]
Melilla	ARIMA(0,1,1)	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)

Cuadro A.4: *Modelos por comunidades*

A.5.2. Tabla modelo por provincia

Provincia	Modelo _ Autoarima	Modelo _ MAPE	Modelo _ AIC
Almería	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(2,1,0)	ARIMA(1,0,0)
Cádiz	ARIMA(0,1,1)(0,0,2)[12]	ARIMA(2,1,2)(0,1,1)[12]	ARIMA(2,1,2)(0,1,1)[12]
Córdoba	ARIMA(2,1,1)(2,0,0)[12]	ARIMA(0,0,1)(2,0,2)[12]	ARIMA(1,0,0)(2,0,0)[12]
Granada	ARIMA(0,1,1)(0,0,2)[12]	ARIMA(1,1,0)(0,1,1)[12]	ARIMA(0,1,1)(1,0,1)[12]
Huelva	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(1,0,0)(2,0,2)[12]	ARIMA(2,0,0)(1,0,0)[12]
Jaén	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(0,0,1)(2,0,2)[12]	ARIMA(0,1,1)(1,0,1)[12]
Málaga	ARIMA(0,1,2)(1,0,2)[12]	ARIMA(2,0,1)(1,0,2)[12]	ARIMA(1,0,0)(1,1,0)[12]
Sevilla	ARIMA(1,1,1)(2,0,0)[12]	ARIMA(0,1,2)(0,1,1)[12]	ARIMA(0,1,2)(1,0,0)[12]
Huesca	ARIMA(0,1,1)(1,0,1)[12]	ARIMA(2,1,0)(0,1,1)[12]	ARIMA(0,1,1)(1,0,1)[12]
Teruel	ARIMA(0,1,1)(1,0,0)[12]	ARIMA(0,1,1)(2,1,2)[12]	ARIMA(0,1,1)(1,0,0)[12]
Zaragoza	ARIMA(1,1,1)(1,0,0)[12]	ARIMA(1,1,0)(0,1,1)[12]	ARIMA(1,0,1)(1,0,0)[12]
Asturias	ARIMA(0,1,3)(0,0,2)[12]	ARIMA(0,1,2)(0,1,1)[12]	ARIMA(1,0,0)(0,0,2)[12]
Islas Baleares	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(1,0,1)(0,0,2)[12]	ARIMA(2,0,0)(0,0,2)[12]
Las Palmas	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(0,1,1)(2,0,0)[12]
Santa Cruz de Tenerife	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(0,1,1)(1,1,1)[12]	ARIMA(0,1,1)(2,0,0)[12]
Cantabria	ARIMA(0,1,1)	ARIMA(1,0,1)(1,1,0)[12]	ARIMA(1,0,1)(1,1,0)[12]
Ávila	ARIMA(0,1,1)(1,0,1)[12]	ARIMA(0,1,1)	ARIMA(0,1,1)
Burgos	ARIMA(1,1,1)(0,0,2)[12]	ARIMA(1,1,1)(0,0,2)[12]	ARIMA(1,0,1)(1,1,0)[12]
León	ARIMA(0,1,2)(1,0,0)[12]	ARIMA(2,0,1)(1,0,1)[12]	ARIMA(0,1,2)(1,0,1)[12]
Palencia	ARIMA(0,1,2)(1,0,0)[12]	ARIMA(1,0,1)(0,1,1)[12]	ARIMA(1,0,1)
Salamanca	ARIMA(0,1,1)(1,0,2)[12]	ARIMA(1,0,1)	ARIMA(1,0,1)
Segovia	ARIMA(0,1,1)	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(2,0,0)
Soria	ARIMA(0,1,3)	ARIMA(1,0,1)(0,1,1)[12]	ARIMA(1,1,1)
Valladolid	ARIMA(0,1,1)(0,0,2)[12]	ARIMA(2,0,0)	ARIMA(0,1,1)
Zamora	ARIMA(0,1,1)(1,0,1)[12]	ARIMA(1,0,1)(1,0,2)[12]	ARIMA(0,1,1)
Albacete	ARIMA(1,1,1)(0,0,2)[12]	ARIMA(1,0,0)(1,1,1)[12]	ARIMA(0,1,1)(2,0,0)[12]
Ciudad Real	ARIMA(0,1,1)	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)(1,0,1)[12]
Cuenca	ARIMA(1,1,1)(1,0,0)[12]	ARIMA(1,1,1)	ARIMA(1,1,1)
Guadalajara	ARIMA(0,1,1)	ARIMA(0,1,1)	ARIMA(0,1,1)
Toledo	ARIMA(0,1,1)(1,0,1)[12]	ARIMA(2,1,0)(0,0,2)[12]	ARIMA(2,1,0)(1,0,0)[12]
Barcelona	ARIMA(0,1,2)(0,1,1)[12]	ARIMA(0,1,0)(2,0,1)[12]	ARIMA(0,1,0)(2,0,1)[12]

Provincia	Modelo_Autoarima	Modelo_MAPE	Modelo_AIC
Girona	ARIMA(0,1,1)(0,0,2)[12]	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(1,0,1)(0,1,1)[12]
Lleida	ARIMA(0,1,1)(1,0,2)[12]	ARIMA(1,0,0)(0,1,1)[12]	ARIMA(1,1,0)(2,1,0)[12]
Tarragona	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(2,1,2)(0,1,1)[12]	ARIMA(0,1,1)(1,0,0)[12]
Alicante	ARIMA(2,1,0)(2,0,0)[12]	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)(1,0,1)[12]
Castellón	ARIMA(0,1,1)(1,0,0)[12]	ARIMA(0,0,2)	ARIMA(0,0,2)(1,0,0)[12]
Valencia	ARIMA(2,1,0)(2,0,0)[12]	ARIMA(2,1,0)(1,1,0)[12]	ARIMA(0,1,1)(2,0,0)[12]
Badajoz	ARIMA(0,1,2)	ARIMA(1,0,1)(1,1,1)[12]	ARIMA(0,1,1)(1,0,1)[12]
Cáceres	ARIMA(0,1,2)(2,0,0)[12]	ARIMA(0,1,1)(1,0,2)[12]	ARIMA(0,1,2)(1,0,2)[12]
A Coruña	ARIMA(1,1,1)(2,0,0)[12]	ARIMA(1,0,1)(0,1,1)[12]	ARIMA(0,0,2)(0,0,2)[12]
Lugo	ARIMA(1,1,1)	ARIMA(1,1,0)	ARIMA(0,1,1)
Ourense	ARIMA(0,1,1)	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)(1,0,1)[12]
Pontevedra	ARIMA(0,1,2)(1,0,2)[12]	ARIMA(2,0,2)(0,1,1)[12]	ARIMA(0,1,2)(0,0,2)[12]
Madrid	ARIMA(0,1,2)(1,0,2)[12]	ARIMA(1,1,2)(2,1,1)[12]	ARIMA(0,1,2)(2,0,0)[12]
Murcia	ARIMA(0,1,1)(2,0,0)[12]	ARIMA(1,1,2)(2,1,1)[12]	ARIMA(0,1,1)(2,0,0)[12]
Navarra	ARIMA(0,1,3)(2,0,0)[12]	ARIMA(0,0,2)(1,1,1)[12]	ARIMA(0,0,2)(1,0,0)[12]
Álava	ARIMA(1,1,1)(1,0,0)[12]	ARIMA(1,0,1)	ARIMA(1,0,1)
Vizcaya	ARIMA(1,1,1)(2,0,0)[12]	ARIMA(1,0,1)(0,1,1)[12]	ARIMA(1,0,1)(0,1,1)[12]
Guipúzcoa	ARIMA(1,1,1)(0,0,2)[12]	ARIMA(2,1,0)(0,1,1)[12]	ARIMA(0,1,1)(0,1,1)[12]
La Rioja	ARIMA(1,1,1)(1,0,0)[12]	ARIMA(2,0,2)(0,1,1)[12]	ARIMA(0,1,1)
Ceuta	ARIMA(1,0,0)(2,0,0)[12]	ARIMA(2,1,0)(0,1,1)[12]	ARIMA(1,0,0)(0,1,1)[12]
Melilla	ARIMA(0,1,1)	ARIMA(0,1,1)(0,1,1)[12]	ARIMA(0,1,1)

Cuadro A.5: *Modelos por provincias*

A.6. Predicciones Bottom-up

A.6.1. Modelos por comunidades




Figura A.6: *Predicciones Bottom-up modelo MAPE por comunidades*




Figura A.7: *Predicciones Bottom-up modelo AIC por comunidades*




Figura A.8: *Predicciones Bottom-up modelo Autoarima por comunidades*

A.6.2. Modelos por provincias




Figura A.9: *Predicciones Bottom-up modelo MAPE por provincias*




Figura A.10: *Predicciones Bottom-up modelo AIC por provincias*




Figura A.11: *Predicciones Bottom-up modelo Autoarima por provincias*

A.7. Error MAPE modelos provinciales

Comunidad	Error MAPE predicciones
Andalucía	9,991
Aragón	11,937
Asturias	13,872
Islas Baleares	9,608
Canarias	13,315
Cantabria	12,146
Castilla y León	9,489
Castilla - La Mancha	16,189
Cataluña	7,427
Comunidad Valenciana	6,667
Extremadura	14,671
Galicia	9,298
Madrid	9,350
Murcia	11,205
Navarra	13,061
País Vasco	10,060
La Rioja	17,342
Ceuta	82,796
Melilla	35,726
Media	16,534

Cuadro A.6: *Error MAPE sobre predicciones de cada comunidad según Top-down*

A.8. Tabla errores *MAPE* de predicciones provinciales

Provincia	Error_ MAPE	Provincia	Error_ MAPE
Almería	13.702352	Lugo	22.689463
Cádiz	10.812783	Ourense	15.011661
Córdoba	16.409009	Pontevedra	10.310495
Granada	12.052512	Madrid	9.318648
Huelva	19.686813	Murcia	10.443840
Jaén	15.545173	Navarra	12.206768
Málaga	12.728072	Araba/Álava	15.978935
Sevilla	7.891906	Bizkaia	13.272344
Huesca	15.702253	Gipuzkoa	12.586464
Teruel	21.981689	La Rioja	16.578327
Zaragoza	12.343907	Ceuta	83.863359
Asturias	13.649919	Melilla	35.122882
Islas Baleares	9.001322	Albacete	17.376931
Las Palmas	15.689686	Ciudad Real	14.414825
Santa Cruz de Tenerife	12.392038	Cuenca	18.346639
Cantabria	11.640410	Guadalajara	17.985622
Ávila	16.315029	Toledo	12.325589
Burgos	15.777092	Barcelona	10.800577
León	15.174029	Girona	10.169317
Palencia	13.790756	Lleida	13.584550
Salamanca	19.853083	Tarragona	8.421216
Segovia	12.882356	Alicante/Alacant	5.900486
Soria	21.502451	Castellón/Castelló	19.013765
Valladolid	13.884455	Valencia/València	8.034929
Zamora	19.694314	Badajoz	19.286091
A Coruña	9.621515	Cáceres	14.559739

Cuadro A.7: Errores *MAPE* por provincia

Apéndice B

Código

Para cualquier consulta con el código véase el repositorio *Github* con enlace <https://github.com/David-Izquierdo-Valentin/tfg-estimaciones-masivas>. El código queda dividido en varios archivos dependiendo del objetivo y de los datos empleados. Se divide pues en código para los modelos de las series nacional, autonómica y provincial y para las diferentes estrategias de predicción. Adicionalmente, se encuentra el código con todas las funciones auxiliares empleadas para el cálculo de todos los modelos.